

## BAB IV

### HASIL DAN PEMBAHASAN

#### 4.1 Analisis Data Eksploratif

Penelitian ini menggunakan data harian harga Bitcoin dan *Crypto Fear and Greed Index* (FGI) dari 1 Februari 2018 hingga 30 Mei 2025. Periode ini dipilih karena data FGI tersedia mulai dari tanggal tersebut melalui situs *Alternative.me*. Data harga Bitcoin diperoleh menggunakan pustaka *yfinance*, yang mencakup harga pembukaan (*open*), tertinggi (*high*), terendah (*low*), penutupan (*close*), dan volume transaksi. *Crypto Fear and Greed Index* (FGI) merupakan indikator kuantitatif yang merepresentasikan sentimen pasar kripto dalam rentang nilai 0 hingga 100, di mana nilai yang lebih rendah mencerminkan dominasi sentimen ketakutan (*fear*), sedangkan nilai yang lebih tinggi mengindikasikan sentimen keserakahan (*greed*). Kedua data yang digunakan dalam penelitian ini tidak mengandung nilai kosong (*missing value*) dan telah siap untuk dianalisis sebagai deret waktu.

Untuk memahami dinamika masing-masing fitur internal Bitcoin, Gambar 4.1 menyajikan visualisasi kelima fitur tersebut dalam format sub-gambar, meliputi harga pembukaan (*Open*), harga tertinggi (*High*), harga terendah (*Low*), harga penutupan (*Close*), dan volume perdagangan harian. Dari visualisasi tersebut, dapat diamati bahwa seluruh fitur harga menunjukkan pola pergerakan yang saling berkorelasi dan mengikuti tren yang relatif serupa, meskipun dengan nilai absolut yang berbeda. Volume perdagangan cenderung meningkat secara signifikan pada periode volatilitas tinggi, terutama selama bull market dan saat krisis pasar terjadi.



(a) Harga Penutupan (*Close*)



(b) Harga Tertinggi (*High*)



(c) Harga Terendah (*Low*)



(d) Harga Pembukaan (*Open*)



(e) Volume Perdagangan Harian

**Gambar 4.1** Visualisasi Fitur Internal Bitcoin (2018–2025)

Selanjutnya, untuk mengkaji hubungan antara harga penutupan Bitcoin dan sentimen pasar, Gambar 4.2 menampilkan visualisasi harga *Close* Bitcoin yang diwarnai berdasarkan nilai FGI. Titik-titik pada grafik diberi gradasi warna dari ungu gelap (*Extreme Fear*) hingga kuning terang (*Extreme Greed*) sesuai dengan nilai indeks pada setiap harinya.



**Gambar 4.2** Pergerakan Harga Penutupan Bitcoin dengan Pewarnaan Berdasarkan *Crypto Fear and Greed Index*

Dari visualisasi ini, dapat diamati bahwa perubahan warna titik-titik FGI cenderung mengikuti atau bahkan mendahului fluktuasi harga Bitcoin yang tajam. Selama periode tekanan pasar seperti krisis COVID-19 (Maret 2020), krisis Terra-LUNA (Mei 2022), dan kejatuhan FTX (November 2022), FGI bergerak ke zona *Extreme Fear* yang ditandai dengan pewarnaan ungu tua. Penurunan tajam harga Bitcoin pada periode tersebut disertai dengan peningkatan volume perdagangan, menunjukkan reaksi pasar yang sangat emosional dan volatil. Hal ini sejalan dengan temuan Karagiannopoulou, Ragazou, Passas, dkk. [34] dan Moro-Visconti dan Cesaretti [35] yang menekankan peran sentimen dalam memperkuat dampak kejadian eksternal terhadap pasar kripto.

Sebaliknya, pada periode ketika pasar menunjukkan optimisme tinggi, seperti awal tahun 2021 dan sepanjang tahun 2024, FGI bertransisi ke warna-warna yang lebih terang seperti kuning dan hijau, mengindikasikan dominasi sentimen positif. Khususnya, lonjakan harga Bitcoin pada awal 2021 bertepatan dengan peningkatan partisipasi institusional, sedangkan tren pemulihan tahun 2024 dipicu oleh persetujuan ETF Bitcoin spot di Amerika Serikat. Pada kedua

periode tersebut, dominasi zona *Greed* dan *Extreme Greed* dapat diamati secara visual. Fenomena ini mendukung hipotesis adanya efek *FOMO* yang mendorong investor masuk ke pasar karena takut tertinggal dari tren kenaikan [36].

Hasil eksplorasi menunjukkan pola temporal antara sentimen pasar dan harga Bitcoin, di mana fase *Extreme Fear* kerap bertepatan dengan penurunan harga, sedangkan sentimen *Greed* cenderung menyertai lonjakan harga. Temuan ini menjadi dasar penambahan fitur korelasi bulanan antara FGI dan komponen harga dalam proses *feature engineering*, guna merepresentasikan dinamika lokal sentimen-harga secara kontekstual dalam model *Multivariate Long Short-Term Memory* (LSTM).

## 4.2 Preprocessing Data

### 4.2.1 Integrasi Data

Tahap awal *preprocessing* dilakukan dengan mengintegrasikan data harga Bitcoin dan indeks FGI berdasarkan format tanggal *datetime* sebagai kunci penggabungan. Sebelum proses integrasi, struktur awal masing-masing data ditampilkan pada Tabel 3.1 dan Tabel 3.2. Hasil integrasi menghasilkan data gabungan yang mencakup seluruh fitur harga Bitcoin beserta nilai FGI untuk setiap observasi harian. Proses ini sangat penting karena model LSTM sensitif terhadap urutan dan kontinuitas data deret waktu, sehingga kesalahan dalam integrasi dapat menyebabkan hilangnya informasi temporal atau menimbulkan bias. Struktur akhir dari data yang telah terintegrasi ditampilkan pada Tabel 4.1.

**Tabel 4.1** Struktur Data Gabungan Setelah Integrasi

Date	Close	High	Low	Open	Volume	FGI
2018-02-02	8830.75	9142.28	7796.49	9142.28	1.272690e+10	15
2018-02-03	9174.91	9430.75	8251.63	8852.12	7.263790e+09	40
2018-02-04	8277.01	9334.87	8031.22	9175.70	7.073550e+09	24
2018-02-05	6955.27	8364.84	6756.68	8270.54	9.285290e+09	11
2018-02-06	7754.00	7850.70	6048.26	7051.75	1.399980e+10	8
...	...	...	...	...	...	...

Date	Close	High	Low	Open	Volume	FGI
2025-05-26	109440.37	110376.88	108735.64	109023.78	4.595046e+10	73
2025-05-27	108994.64	110744.21	107609.55	109440.41	5.745018e+10	74
2025-05-28	107802.33	109298.29	106812.93	108992.17	4.915538e+10	71
2025-05-29	105641.76	108910.05	105374.40	107795.57	5.602275e+10	74
2025-05-30	103998.57	106308.95	103685.79	105646.21	5.765529e+10	60

## 4.2.2 Analisis Korelasi

Sebelum FGI dimasukkan ke dalam model, perlu dilakukan analisis keterkaitan dengan fitur internal Bitcoin. Hal ini bertujuan untuk memastikan bahwa penyertaan variabel eksternal ini secara statistik relevan dan berpotensi meningkatkan kinerja prediktif. Analisis korelasi dilakukan dalam dua pendekatan, yaitu korelasi global dan korelasi per bulan, sebagai dasar dari strategi *feature engineering* [11], [10].

### 4.2.2.1 Korelasi Global

Analisis korelasi global dilakukan menggunakan pendekatan Pearson untuk mengukur hubungan *linear* antara indeks *Crypto Fear and Greed Index* (FGI) dan fitur internal harga Bitcoin, seperti ditunjukkan pada Tabel 4.2. Nilai koefisien korelasi ( $r$ ) antara FGI dan empat fitur harga utama (*close*, *high*, *low*, dan *open*) berada pada kisaran 0,38, sementara korelasi terhadap *volume* tercatat sebesar 0,31. Nilai-nilai tersebut merepresentasikan kekuatan hubungan yang lemah hingga sedang dalam konteks statistik inferensial. Dalam prosedur pengujian Pearson, nilai  $r$  yang diperoleh digunakan untuk menghitung statistik uji  $t$ , yang kemudian dibandingkan dengan distribusi  $t$ -Student untuk menghasilkan nilai  $p$ -value. Seluruh pasangan variabel menunjukkan  $p$ -value yang sangat kecil, yaitu dalam rentang  $10^{-61}$  hingga  $10^{-93}$ , jauh di bawah ambang signifikansi konvensional ( $\alpha = 0,05$ ). Hal ini mengindikasikan bahwa hubungan yang terdeteksi tidak terjadi secara kebetulan, melainkan signifikan secara statistik. Dengan demikian, dapat disimpulkan bahwa terdapat keterkaitan yang bermakna antara FGI dan fitur-fitur harga Bitcoin, sehingga mendukung validitas FGI

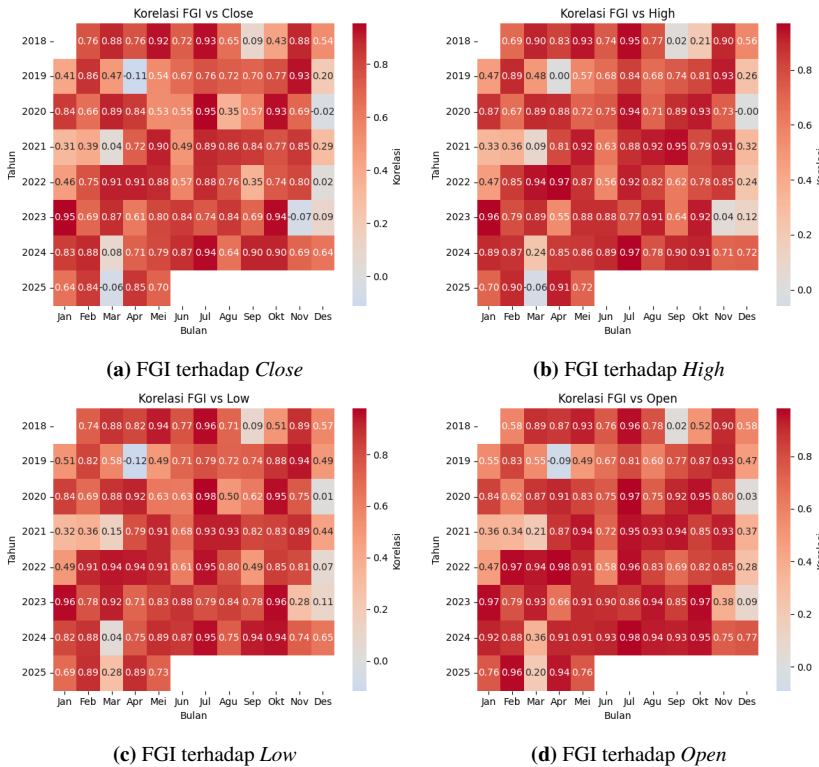
sebagai variabel tambahan yang relevan dalam pemodelan prediktif berbasis *Multivariate* LSTM.

**Tabel 4.2** Nilai Korelasi dan *P-value* antara FGI dan Fitur Harga Bitcoin

Pasangan Variabel	Korelasi (r)	<i>P-value</i>	Signifikan
FGI terhadap Close	0,38	$2,06 \times 10^{-93}$	Ya
FGI terhadap High	0,38	$4,94 \times 10^{-93}$	Ya
FGI terhadap Low	0,38	$1,61 \times 10^{-93}$	Ya
FGI terhadap Open	0,38	$4,57 \times 10^{-93}$	Ya
FGI terhadap Volume	0,31	$4,14 \times 10^{-61}$	Ya


#### 4.2.2.2 Korelasi Per Bulan

Untuk menangkap dinamika temporal secara lebih detail, dilakukan analisis korelasi antara FGI dan masing-masing fitur harga Bitcoin secara terpisah untuk setiap bulan. Hasil yang ditampilkan pada Gambar 4.3 menunjukkan bahwa korelasi bulanan FGI terhadap fitur *close*, *high*, *low*, dan *open* bersifat fluktuatif dan tidak konsisten antar periode. Nilai korelasi berkisar dari sangat rendah hingga mendekati 1, dengan kecenderungan lebih kuat pada bulan-bulan tertentu seperti Maret hingga Oktober dalam beberapa tahun. Oleh karena itu, fitur korelasi per bulan ini berpotensi meningkatkan ketepatan model prediktif dengan memberikan informasi tambahan mengenai kekuatan hubungan sentimen dan harga pada masing-masing jendela waktu.



**Gambar 4.3** Korelasi Per Bulan FGI terhadap Fitur Bitcoin

Sementara itu, Gambar 4.4 menunjukkan bahwa korelasi per bulan antara FGI dan *Volume* cenderung lemah, tidak stabil, dan sering kali negatif. Tidak seperti fitur harga yang memiliki struktur korelasi musiman, hubungan antara sentimen pasar dan volume transaksi lebih acak dan tidak menunjukkan pola yang konsisten secara temporal. Hal ini mengindikasikan bahwa volume transaksi Bitcoin mungkin dipengaruhi oleh faktor-faktor eksternal yang tidak sepenuhnya terekspresikan dalam indeks FGI. Meski demikian, fitur *Volume* tetap dipertahankan sebagai salah satu *input* karena volume merupakan indikator penting dari kekuatan pasar dan likuiditas, serta berperan sebagai sinyal pendukung dalam interpretasi teknikal.



**Gambar 4.4** Korelasi Per Bulan FGI terhadap *Volume*

### 4.2.3 Feature Engineering

Tabel 4.3 menampilkan lima fitur korelasi bulanan antara FGI dan masing-masing komponen harga Bitcoin yang dihasilkan melalui metode Pearson. Nilai korelasi tersebut ditetapkan sebagai fitur statis bulanan dan disematkan ke setiap baris data harian sesuai bulan terkait. Strategi ini dirujuk dari temuan bahwa keterkaitan antara indikator pasar dan harga aset cenderung berubah seiring waktu dan tergantung pada konteks pasar. Sebagaimana ditunjukkan oleh Choi [11], penggunaan korelasi antar saham sebagai *input* dinamis dalam model LSTM dapat meningkatkan kinerja prediksi. Hal serupa juga ditemukan oleh Agrawal dkk. [10], yang menunjukkan bahwa penambahan fitur korelasi antar indikator teknikal memberikan dampak positif terhadap akurasi model. Dengan pendekatan ini, informasi hubungan temporal antara sentimen dan harga berhasil direpresentasikan tanpa menambah kompleksitas dimensi waktu. Seluruh fitur hasil *feature engineering* digunakan dalam Model 2 sebagai bagian dari vektor *input* pada arsitektur *Multivariate Long Short-Term Memory* (LSTM).

**Tabel 4.3** Korelasi Per Bulan FGI terhadap Fitur Harga Bitcoin

Bulan	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
2018-02	0.5849	0.6890	0.7372	0.7562	-0.2128



<b>Bulan</b>	<i>corr fgi_open</i>	<i>corr fgi_high</i>	<i>corr fgi_low</i>	<i>corr fgi_close</i>	<i>corr fgi_volume</i>
2018-03	0.8922	0.9047	0.8823	0.8826	0.3771
2018-04	0.8679	0.8266	0.8172	0.7625	0.6941
2018-05	0.9302	0.9316	0.9386	0.9233	0.7348
2018-06	0.7622	0.7408	0.7721	0.7240	0.0271
...	...	...	...	...	...
2025-01	0.7609	0.7045	0.6878	0.6444	0.1440
2025-02	0.9647	0.8956	0.8878	0.8402	-0.3445
2025-03	0.2027	-0.0588	0.2815	-0.0592	-0.3561
2025-04	0.9416	0.9137	0.8934	0.8520	-0.3137
2025-05	0.7595	0.7157	0.7298	0.7005	0.4537

Dengan demikian, daftar fitur yang digunakan dalam masing-masing model disajikan pada Tabel 4.4.

**Tabel 4.4** Perbandingan Fitur yang Digunakan pada Model 1 dan Model 2

<b>Model 1</b>	<b>Model 2</b>
<i>Open Price</i>	<i>Open Price</i>
<i>High Price</i>	<i>High Price</i>
<i>Low Price</i>	<i>Low Price</i>
<i>Close Price</i>	<i>Close Price</i>
<i>Volume</i>	<i>Volume</i>
	<i>Fear and Greed Index (FGI)</i>
	<i>corr_fgi_open</i>
	<i>corr_fgi_high</i>
	<i>corr_fgi_low</i>
	<i>corr_fgi_close</i>
	<i>corr_fgi_volume</i>

#### 4.2.4 Pembagian dan Normalisasi Data

Setelah proses rekayasa fitur, data dibagi secara berurutan berdasarkan waktu menjadi tiga bagian, yaitu data latih sebesar 70%, data validasi 10%, dan data uji 20%. Pembagian dilakukan tanpa pengacakan

(*shuffling*) untuk menjaga konsistensi pola temporal dan menghindari *data leakage*, sesuai dengan prinsip umum dalam pemodelan deret waktu [37]. Pembagian ini memungkinkan model belajar dari pola historis masa lalu dan dievaluasi terhadap data masa depan secara berurutan, yang merefleksikan kondisi prediksi di dunia nyata. Rincian jumlah baris pada masing-masing bagian ditampilkan pada Tabel 4.5.

**Tabel 4.5** Pembagian Dataset Setelah Rekayasa Fitur

Jenis Data	Persentase	Jumlah Baris
Data Latih	70%	1.869
Data Validasi	10%	267
Data Uji	20%	535
<b>Total</b>	100%	2.671

Seluruh fitur numerik kemudian dinormalisasi ke dalam rentang  $[0, 1]$  menggunakan metode *Min-Max Scaler* [17], sebagaimana dijelaskan pada Persamaan 2.3. Proses normalisasi didasarkan pada nilai minimum dan maksimum dari data latih untuk menghindari terjadinya *data leakage*, dan transformasi yang sama diterapkan secara konsisten pada data validasi maupun uji. Visualisasi hasil normalisasi untuk fitur *Close* ditunjukkan pada Gambar 4.5. Pada gambar tersebut, garis hitam merepresentasikan nilai harga penutupan yang telah dinormalisasi. Area berwarna biru menggambarkan data latih (70%), yang berakhir pada batas vertikal biru putus-putus. Selanjutnya, area kuning menandai rentang data validasi (10%), dengan batas akhirnya ditunjukkan oleh garis vertikal merah putus-putus. Sementara itu, area merah muda menunjukkan rentang data uji (20%) yang mencakup bagian akhir dari deret waktu. Visualisasi ini menunjukkan bahwa fitur *Close* telah berhasil disesuaikan skalanya di seluruh *subset* data, sehingga memastikan proporsi dan distribusi nilai tetap konsisten sepanjang proses pelatihan hingga evaluasi model.



**Gambar 4.5** Hasil Pembagian Data *Close* Setelah Normalisasi

Untuk memberikan gambaran konkret mengenai hasil normalisasi, Tabel 4.6 menyajikan cuplikan data latih setelah transformasi *Min-Max Scaling*. Skala ini ditentukan berdasarkan nilai minimum dan maksimum pada *subset* data latih.

**Tabel 4.6** Data Latih Setelah Normalisasi

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.09	0.09	0.07	0.09	0.03	0.11	0.63	0.71	0.78	0.82	0.20
0.09	0.09	0.08	0.09	0.01	0.39	0.63	0.71	0.78	0.82	0.20
0.08	0.09	0.08	0.09	0.01	0.21	0.63	0.71	0.78	0.82	0.20
0.06	0.08	0.06	0.08	0.02	0.07	0.63	0.71	0.78	0.82	0.20
0.07	0.07	0.05	0.06	0.03	0.03	0.63	0.71	0.78	0.82	0.20
...	...	...	...	...	...	...	...	...	...	...
0.33	0.34	0.33	0.33	0.12	0.50	0.95	0.92	0.95	0.92	0.30
0.34	0.33	0.33	0.33	0.09	0.52	0.95	0.92	0.95	0.92	0.30
0.38	0.37	0.34	0.34	0.14	0.51	0.95	0.92	0.95	0.92	0.30
0.37	0.37	0.37	0.38	0.09	0.66	0.95	0.92	0.95	0.92	0.30
0.39	0.38	0.38	0.37	0.10	0.64	0.95	0.92	0.95	0.92	0.30

Selanjutnya, Tabel 4.7 menampilkan cuplikan data validasi yang telah dinormalisasi menggunakan skala yang sama dengan data latih. Konsistensi transformasi ini bertujuan untuk menjaga integritas distribusi data antar *subset*.

**Tabel 4.7** Data Validasi Setelah Normalisasi

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.38	0.39	0.38	0.39	0.12	0.68	0.95	0.92	0.95	0.92	0.30
0.39	0.38	0.38	0.38	0.10	0.70	0.95	0.92	0.95	0.92	0.30
0.37	0.39	0.37	0.39	0.09	0.63	0.95	0.92	0.95	0.92	0.30

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.39	0.39	0.38	0.37	0.06	0.58	0.95	0.92	0.95	0.92	0.30
0.38	0.38	0.38	0.39	0.07	0.62	0.95	0.92	0.95	0.92	0.30
...	...	...	...	...	...	...	...	...	...	...
0.62	0.62	0.63	0.63	0.07	0.74	0.17	0.12	0.21	0.19	0.51
0.64	0.63	0.63	0.62	0.06	0.74	0.17	0.12	0.21	0.19	0.51
0.63	0.63	0.64	0.64	0.04	0.76	0.17	0.12	0.21	0.19	0.51
0.63	0.62	0.64	0.63	0.03	0.77	0.17	0.12	0.21	0.19	0.51
0.59	0.62	0.59	0.63	0.11	0.77	0.17	0.12	0.21	0.19	0.51

Terakhir, Tabel 4.8 menyajikan cuplikan data uji yang telah melalui proses normalisasi berdasarkan rentang nilai pada data latih. Beberapa fitur seperti *close*, *high*, *low*, dan *open* menunjukkan nilai di atas 1, yang menandakan bahwa data uji mengandung nilai aktual yang melebihi maksimum pada data pelatihan. Hal ini umum terjadi dalam konteks deret waktu, terutama ketika terjadi tren kenaikan harga setelah periode pelatihan [37].

**Tabel 4.8** Data Uji Setelah Normalisasi

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.59	0.59	0.59	0.59	0.06	0.69	0.17	0.12	0.21	0.19	0.51
0.62	0.61	0.59	0.59	0.07	0.67	0.17	0.12	0.21	0.19	0.51
0.62	0.61	0.61	0.62	0.07	0.74	0.17	0.12	0.21	0.19	0.51
0.60	0.61	0.61	0.62	0.05	0.72	0.17	0.12	0.21	0.19	0.51
0.61	0.60	0.61	0.60	0.03	0.69	0.17	0.12	0.21	0.19	0.51
...	...	...	...	...	...	...	...	...	...	...
1.65	1.63	1.67	1.64	0.12	0.76	0.79	0.74	0.77	0.76	0.71
1.64	1.64	1.65	1.65	0.16	0.77	0.79	0.74	0.77	0.76	0.71
1.63	1.62	1.64	1.64	0.13	0.73	0.79	0.74	0.77	0.76	0.71
1.59	1.61	1.62	1.63	0.15	0.77	0.79	0.74	0.77	0.76	0.71
1.57	1.57	1.59	1.59	0.16	0.61	0.79	0.74	0.77	0.76	0.71

### 4.3 Konfigurasi *Hyperparameter*

Proses tuning dilakukan untuk memperoleh konfigurasi *hyperparameter* yang menghasilkan kinerja prediksi terbaik. Ruang pencarian terdiri atas 5.832 kombinasi untuk masing-masing model.

Mengingat besarnya ruang eksplorasi, algoritma *Hyperband* digunakan untuk menyeleksi kandidat terbaik secara efisien melalui mekanisme *successive halving*. Dari total ruang tersebut, sebanyak 763 konfigurasi dievaluasi untuk tiap model. Selanjutnya, 50 kombinasi terbaik dengan nilai *validation loss* terendah diseleksi dan dianalisis lebih lanjut pada bagian berikut.

### 4.3.1 Konfigurasi dan Hasil Tuning Model 1

Model 1 dibangun dengan hanya menggunakan fitur historis internal Bitcoin, tanpa informasi eksternal seperti *Fear and Greed Index* (FGI). Konfigurasi terbaik terdiri atas satu lapisan *LSTM* dengan 128 unit, *dropout* sebesar 0,1, regularisasi kernel L2 sebesar 0,0001, *batch size* 32, dan *learning rate* 0,01. Panjang urutan waktu (*sequence length*) optimal adalah 14 hari. Kombinasi ini menghasilkan nilai MSE validasi minimum sebesar 0,000101. Detail lengkap konfigurasi terbaik ini dapat dilihat pada Tabel 4.9, yang menyajikan seluruh *hyperparameter* dan nilai terbaik yang digunakan dalam pelatihan akhir.

**Tabel 4.9** Parameter Terbaik untuk Model 1

<i>Hyperparameter</i>	Nilai Terbaik
<i>Sequence Length</i>	14
Jumlah Lapisan <i>LSTM</i>	1
Jumlah Unit	128
<i>Dropout</i>	0.1
Regulasi Kernel (L2)	0.0001
<i>Batch Size</i>	32
<i>Optimizer</i>	Adam
<i>Learning Rate</i>	0.01

Tabel 4.10 menyajikan sepuluh kombinasi *hyperparameter* dengan nilai MSE validasi terendah dan tertinggi dari seluruh proses tuning pada Model 1. Hasil menunjukkan bahwa konfigurasi terbaik umumnya menggunakan arsitektur sederhana (satu lapisan *LSTM*),

jumlah unit antara 64 hingga 128, *dropout* rendah, serta *optimizer* Adam yang lebih stabil untuk data deret waktu. Sebaliknya, konfigurasi dengan performa buruk cenderung melibatkan arsitektur kompleks (dua atau tiga lapisan), *learning rate* tinggi (0,1), dan *optimizer* RMSprop yang menunjukkan instabilitas dalam konteks ini. Dari seluruh hasil, ID 462 dipilih sebagai konfigurasi terbaik karena memiliki nilai MSE validasi paling rendah dan struktur yang seimbang antara kompleksitas dan stabilitas. Meskipun ID 716 mencatatkan nilai MSE identik, parameter seperti *batch size* yang lebih besar dan *dropout* yang lebih tinggi pada ID 716 menunjukkan fluktuasi pelatihan yang lebih besar, sehingga ID 462 lebih layak dijadikan dasar arsitektur akhir Model 1.

**Tabel 4.10** Konfigurasi *Hyperparameter Tuning* Model 1

ID	MSE	Seq L	LSTM	Unit			Dropout			L2	Opti mizer	Learning Rate	Batch Size
				1	2	3	1	2	3				
462	0.000101	14	1	128	96	96	0.10	0.10	0.01	0.0001	adam	0.01	32
716	0.000101	21	1	64	128	96	0.20	0.20	0.20	0.0001	adam	0.01	64
208	0.000102	7	1	64	128	128	0.20	0.01	0.20	0.0001	adam	0.01	64
654	0.000102	21	1	64	64	128	0.01	0.20	0.10	0.0001	adam	0.01	64
650	0.000102	21	1	64	64	128	0.01	0.20	0.10	0.0001	adam	0.01	64
463	0.000103	14	1	64	64	96	0.10	0.01	0.20	0.0010	adam	0.01	32
742	0.000103	21	1	128	128	64	0.10	0.10	0.01	0.0001	adam	0.01	32
400	0.000104	14	1	64	64	128	0.10	0.10	0.01	0.0001	adam	0.0010	32
717	0.000104	21	1	96	64	128	0.20	0.01	0.10	0.0001	adam	0.01	128
753	0.000106	21	1	96	128	128	0.10	0.01	0.01	0.0010	adam	0.01	32
...	...	...	...	...	...	...	...	...	...	...	...	...	...
263	1.439833	14	3	128	64	96	0.10	0.10	0.01	0.0001	rmsprop	0.10	128
580	2.015894	21	3	128	96	96	0.01	0.20	0.20	0.0001	rmsprop	0.10	64
86	2.049962	7	1	96	64	64	0.01	0.10	0.20	0.01	rmsprop	0.10	128
274	2.498899	14	2	64	64	96	0.01	0.01	0.10	0.01	rmsprop	0.10	64
600	2.693460	21	1	128	96	96	0.20	0.20	0.10	0.01	rmsprop	0.10	128
88	3.602457	7	2	96	96	64	0.10	0.01	0.10	0.0010	rmsprop	0.10	32
510	4.524909	21	2	64	96	NaN	0.20	0.01	NaN	0.0001	rmsprop	0.10	32
561	5.485112	21	1	128	64	96	0.20	0.20	0.10	0.0001	rmsprop	0.10	32
330	9.198813	14	2	64	128	128	0.10	0.10	0.20	0.0010	rmsprop	0.10	128
63	10.657529	7	3	64	96	128	0.01	0.01	0.20	0.01	rmsprop	0.10	32

### 4.3.2 Konfigurasi dan Hasil Tuning Model 2

Model 2 dilatih dengan memasukkan fitur tambahan berupa *Fear and Greed Index* (FGI) dan korelasi bulanan FGI terhadap fitur-fitur harga dan volume. Hasil tuning menunjukkan konfigurasi terbaik terdiri dari satu lapisan *LSTM* dengan 128 unit, *dropout* 0,01, regularisasi kernel L2 sebesar 0,0001, *batch size* 64, dan *learning rate* 0,01, dengan panjang urutan waktu optimal selama 7 hari. Kombinasi ini menghasilkan nilai MSE validasi minimum sebesar 0,000102. Detail konfigurasi terbaik untuk Model 2 disajikan pada Tabel 4.11, yang memuat seluruh parameter beserta nilai optimal hasil tuning.

**Tabel 4.11** Parameter Terbaik untuk Model 2

<i>Hyperparameter</i>	Nilai Terbaik
<i>Sequence Length</i>	7
Jumlah Lapisan <i>LSTM</i>	1
Jumlah Unit	128
<i>Dropout</i>	0.01
Regulasi Kernel (L2)	0.0001
<i>Batch Size</i>	64
<i>Optimizer</i>	Adam
<i>Learning Rate</i>	0.01

Tabel 4.12 merangkum sepuluh kombinasi *hyperparameter* terbaik dan terburuk dari 762 konfigurasi yang diuji untuk Model 2. Pola konfigurasi optimal cenderung menyerupai Model 1, terutama pada pemilihan *optimizer* Adam dan *learning rate* 0,01. Namun, adanya fitur eksternal tampaknya mempercepat pembelajaran pola pasar, sebagaimana ditunjukkan oleh panjang urutan waktu optimal yang lebih pendek (7 hari). Sebaliknya, konfigurasi dengan performa buruk umumnya memiliki arsitektur kompleks dan *learning rate* tinggi, serta menggunakan *optimizer* RMSprop, yang juga menghasilkan MSE tinggi pada Model 1. Tabel ini menegaskan bahwa penambahan informasi kontekstual (FGI dan korelasi) dapat meningkatkan efisiensi pembelajaran tanpa menambah kompleksitas arsitektur secara

signifikan.

**Tabel 4.12** Konfigurasi *Hyperparameter Tuning* Model 2

ID	MSE	Seq L	LSTM	Unit			Dropout			L2	Opti mizer	Learning Rate	Batch Size
				1	2	3	1	2	3				
146	0.000102	7	1	128	96	64	0.01	0.20	0.20	0.0001	adam	0.01	64
250	0.000104	7	1	64	96	96	0.01	0.10	0.01	0.0001	adam	0.01	64
463	0.000104	14	1	128	96	64	0.10	0.10	0.10	0.0010	adam	0.01	32
401	0.000105	14	1	128	64	64	0.20	0.01	0.01	0.0001	adam	0.01	32
502	0.000105	14	1	128	96	64	0.10	0.10	0.01	0.0001	adam	0.01	32
400	0.000106	14	1	128	96	128	0.10	0.10	0.20	0.0001	adam	0.01	32
654	0.000107	21	1	96	128	128	0.20	0.10	0.20	0.0001	adam	0.01	64
147	0.000107	7	1	128	128	96	0.01	0.01	0.10	0.0001	adam	0.0010	64
716	0.000112	21	1	128	128	128	0.10	0.10	0.01	0.0001	adam	0.01	32
209	0.000113	7	1	64	64	96	0.20	0.20	0.01	0.0001	adam	0.0010	32
...	...	...	...	...	...	...	...	...	...	...	...	...	...
329	1.467640	14	1	96	64	128	0.01	0.01	0.10	0.0001	rmsprop	0.10	64
597	1.574949	21	1	96	128	96	0.10	0.01	0.20	0.01	rmsprop	0.10	64
267	1.795949	14	1	128	64	64	0.10	0.20	0.20	0.01	adam	0.10	128
668	1.970428	21	3	96	64	128	0.01	0.20	0.10	0.01	rmsprop	0.10	64
277	2.083627	14	2	64	96	96	0.20	0.20	0.10	0.0010	rmsprop	0.10	32
61	2.336715	7	3	96	128	96	0.20	0.01	0.01	0.0001	rmsprop	0.10	64
479	2.402305	14	3	128	64	128	0.10	0.01	0.20	0.01	rmsprop	0.10	32
336	2.617528	14	2	96	96	128	0.20	0.10	0.20	0.01	rmsprop	0.10	32
266	4.868916	14	3	64	128	128	0.20	0.20	0.20	0.01	rmsprop	0.10	64
54	10.804993	7	2	64	128	64	0.10	0.01	0.01	0.0010	rmsprop	0.10	32

### 4.3.3 Analisis Distribusi Konfigurasi Terbaik

Evaluasi dilakukan terhadap distribusi *hyperparameter* dari 50 kombinasi terbaik berdasarkan nilai MSE validasi, yang diambil dari total 763 konfigurasi yang diuji untuk masing-masing model. Hasil distribusi ini ditampilkan pada Tabel 4.13 dan memberikan gambaran umum mengenai kecenderungan pemilihan arsitektur selama proses tuning. Hasilnya menunjukkan kecenderungan arsitektur yang serupa pada kedua model, dominasi satu lapisan *LSTM* dan *optimizer* Adam. Namun, Model 2 menunjukkan proporsi RMSprop lebih tinggi (28%) dibanding Model 1 (8%) serta preferensi unit lebih besar (128 unit pada 48% kombinasi terbaik). Dari sisi *sequence length*, Model 1 lebih condong ke 21 hari (50%), sementara Model 2 ke 7 hari (42%),



mencerminkan perbedaan preferensi temporal yang konsisten. Temuan ini mendukung bahwa arsitektur sederhana namun stabil efektif untuk mempelajari dinamika harga Bitcoin, khususnya saat fitur sentimen eksternal disertakan.


**Tabel 4.13** Distribusi 50 Kombinasi *Hyperparameter* Terbaik untuk Kedua Model

<i>Hyperparameter</i>	Model 1	Model 2
<i>Optimizer</i>		
Adam	92.0%	72.0%
RMSprop	8.0%	28.0%
Jumlah Lapisan LSTM		
1 <i>Layer</i>	94.0%	98.0%
2 <i>Layer</i>	6.0%	2.0%
Jumlah <i>Unit</i> LSTM		
64 <i>Unit</i>	56.0%	26.0%
96 <i>Unit</i>	20.0%	26.0%
128 <i>Unit</i>	24.0%	48.0%
<i>Batch Size</i>		
32	46.0%	50.0%
64	44.0%	44.0%
128	10.0%	6.0%
<i>Dropout</i>		
0.01	38.0%	36.0%
0.10	36.0%	32.0%
0.20	26.0%	32.0%
Regulasi Kernel (L2)		
0.0001	62.0%	78.0%
0.0010	38.0%	22.0%
<i>Sequence Length</i>		
7 Hari	16.0%	42.0%
14 Hari	34.0%	30.0%
21 Hari	50.0%	28.0%

#### 4.4 Struktur *Input*


Proses *hyperparameter tuning* menghasilkan struktur *input* yang berbeda untuk masing-masing model, sesuai konfigurasi optimal yang

diperoleh. Model 1 membentuk tensor berdimensi (32, 14, 5), yang terdiri dari 32 sampel per *batch*, masing-masing mencakup urutan waktu selama 14 hari dengan lima fitur internal Bitcoin. Struktur tensor tiga dimensi tersebut ditampilkan pada Gambar 4.6, yang menggambarkan bagaimana data historis dikelompokkan ke dalam *batch* untuk proses pembelajaran.



**Gambar 4.6** Struktur Tensor Optimal Model 1 (32, 14, 5)


Gambar 4.7 berikut menjelaskan mekanisme pembentukan pasangan *input-output* Model 1 dengan pendekatan *sliding window*. Dalam proses ini, 14 langkah waktu digunakan untuk memprediksi nilai pada hari ke-15, kemudian jendela digeser satu hari ke depan untuk membentuk pasangan baru.



**Gambar 4.7** Mekanisme *Sliding Window* Model 1 dengan *Sequence Length* 14


Model 2 menghasilkan struktur *input* dengan dimensi tensor (64, 7, 11), yang mencakup 64 sampel per *batch*, masing-masing berisi 7 langkah waktu dan 11 fitur. Penambahan enam fitur eksternal—terdiri dari nilai FGI dan lima korelasi bulanannya—meningkatkan kedalaman representasi input. Gambar 4.8 menunjukkan struktur tensor tersebut, di mana setiap baris representasi

mencerminkan urutan data yang kaya secara fitur namun lebih singkat secara temporal.



**Gambar 4.8** Struktur Tensor Optimal Model 2 (64, 7, 11)

Adapun Gambar 4.9 menampilkan proses *sliding window* pada Model 2. Tujuh hari berturut-turut digunakan sebagai *input* untuk memprediksi nilai pada hari ke-8, dengan jendela yang digeser setiap hari.



**Gambar 4.9** Mekanisme *Sliding Window* Model 2 dengan *Sequence Length* 7

## 4.5 Pelatihan Model

Pelatihan dilakukan untuk meminimalkan kesalahan prediksi harga penutupan Bitcoin melalui proses iteratif yang mencakup perhitungan *loss*, pembaruan bobot menggunakan algoritma *optimizer*, dan evaluasi berulang selama sejumlah *epoch*. Konfigurasi *hyperparameter* optimal diperoleh terlebih dahulu melalui algoritma *Hyperband*, yang mengandalkan alokasi sumber daya adaptif tanpa menyimpan bobot pelatihan. Oleh karena itu, setelah konfigurasi terbaik diidentifikasi, model dilatih ulang dari awal menggunakan seluruh data latih. Kedua model mengadopsi arsitektur identik, terdiri atas satu lapisan *LSTM* berisi 128 unit, satu *Dropout layer*, dan satu lapisan *Dense* untuk

regresi. Tabel 4.14 menampilkan ringkasan arsitektur dan jumlah parameter. Perbedaan utama terletak pada dimensi input, dimana Model 1 menerima 5 fitur, sedangkan Model 2 menggunakan 11 fitur. Hal ini menyebabkan jumlah parameter *LSTM* bertambah dari 68 608 menjadi 71 680. Secara keseluruhan, Model 2 memiliki total parameter latih sebesar 71 809, sedikit lebih banyak dibanding Model 1 yang berjumlah 68 737. Kompleksitas input Model 2 juga tercermin dari parameter yang dikelola oleh *optimizer*, yaitu 143 620 dibandingkan 137 476 pada Model 1.


**Tabel 4.14** Ringkasan Arsitektur dan Jumlah Parameter Model

<i>Layer (Type)</i>	<i>Output Shape</i>	<i>Param #</i>
<i>Model 1</i>		
LSTM	(None, 128)	68 608
Dropout	(None, 128)	0
Dense	(None, 1)	129
Total <i>params</i>		68 737
Trainable <i>params</i>		68 737
Non-trainable <i>params</i>		0
Optimizer <i>params</i>		137 476
<i>Model 2</i>		
LSTM	(None, 128)	71 680
Dropout	(None, 128)	0
Dense	(None, 1)	129
Total <i>params</i>		71 809
Trainable <i>params</i>		71 809
Non-trainable <i>params</i>		0
Optimizer <i>params</i>		143 620

#### 4.5.1 Evaluasi Kurva *Loss*


Kurva *loss* pada Gambar 4.10 menunjukkan perubahan nilai MSE selama proses pelatihan sebagai indikator konvergensi dan kemampuan generalisasi model. *Training loss* (garis biru) dihitung sebagai rata-rata kesalahan per *batch* dalam satu *epoch*, sedangkan *validation loss* (garis oranye) dihitung satu kali di akhir *epoch* pada model yang telah

diperbarui, sehingga sering kali berada di bawah *training loss* pada fase awal. Dari nilai awal sebesar 0,0392, *training loss* menurun drastis selama lima *epoch* pertama, mengindikasikan bahwa model dengan cepat mengenali pola dasar dalam data. Setelah melewati *epoch* ke-20, kedua kurva bergerak stabil dan saling mendekat, mencerminkan kemampuan generalisasi yang baik dan tidak terjadi *overfitting*. Nilai *validation loss* terendah tercapai pada *epoch* ke-82 sebesar  $1.96 \times 10^{-4}$ , dengan sedikit fluktuasi pada *epoch* ke-84 yang masih tergolong wajar dalam proses pelatihan.



**Gambar 4.10** Kurva *Loss* Model 1.

Sementara itu, Gambar 4.11 memperlihatkan kurva *loss* Model 2 selama pelatihan. Nilai awal *training loss* sebesar 0,0986 lebih tinggi dibandingkan Model 1, mencerminkan kompleksitas *input* akibat penambahan fitur eksternal. Meskipun demikian, penurunan *loss* terjadi sangat cepat sejak *epoch* pertama dan segera mencapai nilai mendekati nol, menunjukkan adaptasi model yang efisien terhadap pola multivariabel. Sepanjang 150 *epoch*, *validation loss* (garis oranye) menurun secara konsisten tanpa fluktuasi berarti, dengan nilai terendah  $1.02 \times 10^{-4}$  pada *epoch* ke-123. Stabilitas ini mengindikasikan bahwa keberadaan fitur tambahan seperti *Fear* and *Greed Index* dan korelasinya membantu menyampaikan sinyal yang lebih informatif, sehingga proses pembelajaran menjadi lebih cepat, stabil, dan tidak bergantung pada konteks historis yang panjang.




**Gambar 4.11** Kurva *Loss* Model 2.

#### 4.5.2 Analisis Konvergensi Bobot Jaringan


Konvergensi bobot terjadi ketika nilai bobot dalam lapisan *LSTM* mencapai kestabilan seiring bertambahnya jumlah *epoch*, menandakan bahwa model telah mengenali pola yang konsisten dari data. Untuk memonitor dinamika ini, digunakan statistik deskriptif berupa nilai rata-rata dan standar deviasi bobot. Berbeda dengan pandangan sederhana, dalam optimisasi stokastik modern seperti Adam, konvergensi yang stabil tidak selalu menandakan bahwa proses berada di zona curam. Sebaliknya, menurut Kingma dan Ba [21], ketika proses optimisasi mendekati titik optimum, *signal-to-noise ratio* (SNR) pada gradien cenderung menurun, sehingga pembaruan bobot menjadi lebih kecil secara otomatis sebagai bentuk *automatic annealing*. Hal ini sejalan dengan ulasan oleh Ruder [38], yang menyatakan bahwa *optimizer* adaptif seperti Adam dirancang untuk menavigasi *loss landscape* yang kompleks dan mencapai konvergensi di area yang lebih landai.

Pada Model 1, visualisasi Gambar 4.12 memperlihatkan dinamika bobot yang masih relatif fluktuatif. Gambar 4.12a menampilkan kurva berwarna biru yang menunjukkan rata-rata bobot kernel *LSTM*. Kurva ini naik tajam dari nilai awal sekitar  $-0,024$  menuju nol dalam 20 *epoch* pertama, yang dapat diartikan sebagai fase adaptasi cepat awal

(ditandai oleh area abu-abu). Namun, setelah fase ini, fluktuasi mulai muncul secara tidak merata, khususnya setelah *epoch* ke-100. Gambar 4.12b mendukung temuan ini, di mana kurva merah yang menggambarkan standar deviasi bobot tidak sepenuhnya stabil dan menunjukkan getaran kecil di sepanjang pelatihan. Kondisi ini mencerminkan bahwa Adam bekerja dalam lingkungan yang cukup bising, tipikal data keuangan yang penuh noise. Meski demikian, pola penurunan yang tetap konsisten menunjukkan bahwa model masih menuju arah konvergensi.



(a) Rata-rata Bobot




(b) Standar Deviasi


**Gambar 4.12** Konvergensi Bobot Jaringan Model 1

Sebaliknya, Model 2 pada Gambar 4.13 menunjukkan pola konvergensi yang jauh lebih stabil dan efisien. Gambar 4.13a memperlihatkan kurva biru yang naik tajam dari  $-0,042$  hingga mendekati nol dalam 20 *epoch* pertama, yang juga ditandai sebagai fase adaptasi cepat (area berwarna abu-abu). Setelah itu, rata-rata bobot tetap mendekati nol tanpa fluktuasi berarti sepanjang sisa

pelatihan. Sementara itu, Gambar 4.13b menampilkan kurva merah yang menurun halus dari nilai awal 0,069 ke sekitar 0,011, dengan bentuk kurva yang bersih dan konsisten tanpa guncangan. Pola ini mengindikasikan bahwa penambahan variabel *Fear & Greed Index* (FGI) memberikan sinyal gradien yang lebih informatif dan tidak terlalu bising kepada model. Dengan sinyal yang lebih bersih, mekanisme estimasi momen adaptif dalam Adam dapat bekerja lebih efektif, menghasilkan proses pelatihan yang lebih tenang dan konvergensi yang lebih cepat menuju titik minimum[21]. Kestabilan ini juga tercermin pada nilai *loss* validasi yang cenderung datar, menegaskan bahwa penambahan FGI tidak hanya meningkatkan akurasi prediksi tetapi juga efisiensi proses pembelajaran.



(a) Rata-rata Bobot



(b) Standar Deviasi

**Gambar 4.13** Konvergensi Bobot Jaringan Model 2



## 4.6 Evaluasi Hasil Prediksi

### 4.6.1 Analisis Hasil Evaluasi dengan MAPE

Tahap evaluasi bertujuan untuk mengukur kemampuan generalisasi model dalam memprediksi harga penutupan Bitcoin berdasarkan data uji yang tidak digunakan selama proses pelatihan. Evaluasi dilakukan menggunakan metrik *Mean Absolute Percentage Error* (MAPE), yang menghitung rata-rata kesalahan absolut dalam bentuk persentase terhadap nilai aktual. MAPE merupakan salah satu metrik yang paling banyak digunakan dalam prediksi pasar keuangan karena bersifat skala-independen dan memiliki interpretasi yang intuitif [15], [39]. Dalam konteks aset kripto yang volatil, model dengan MAPE di bawah 10% dianggap cukup andal [40]. Tabel 4.15 menyajikan nilai MAPE dari dua model yang diuji dalam penelitian ini.

**Tabel 4.15** Perbandingan Kinerja Final Model Berdasarkan Nilai MAPE

Model	MAPE (%)
Model 1	6.02
Model 2	2.33


### 4.6.2 Analisis Hasil Prediksi

Gambar 4.14 menampilkan hasil prediksi akhir menggunakan Model 2, yaitu model *Multivariate LSTM* yang mengintegrasikan indikator sentimen *Fear and Greed Index* (FGI) serta lima fitur korelasi bulanan terhadap fitur internal Bitcoin. Dalam visualisasi ini, garis hitam menunjukkan harga aktual, sedangkan garis biru merepresentasikan prediksi model. Area abu-abu mengilustrasikan selisih antara prediksi dan data aktual sebagai indikator galat.

Model ini berhasil mencapai tingkat akurasi tinggi dengan nilai MAPE sebesar 2,33%, menandakan keunggulan signifikan dibanding baseline. Secara visual, prediksi mengikuti arah tren harga dengan lebih presisi, termasuk dalam situasi perubahan tren yang ekstrem. Tingkat keterlambatan (lag) juga tampak minimal. Temuan ini memperkuat

hasil studi sebelumnya oleh Mahdi *et al.* [15], Jiang *et al.* [41], dan Agrawal *et al.* [40], yang menegaskan bahwa integrasi indikator sentimen ke dalam model prediktif mampu meningkatkan akurasi dan responsivitas terhadap dinamika pasar kripto.

Adopsi fitur korelasi bulanan dalam penelitian ini juga berperan penting dalam menangkap dinamika relasi jangka pendek antara sentimen dan harga, memungkinkan model menyesuaikan bobot input secara kontekstual. Secara keseluruhan, hasil ini menunjukkan bahwa integrasi FGI tidak hanya meningkatkan akurasi kuantitatif, tetapi juga memperkuat stabilitas dan adaptabilitas model dalam menghadapi volatilitas pasar.



**Gambar 4.14** Prediksi Model 2 terhadap Data Uji (dengan FGI dan korelasi bulanan)