

**ANALISIS PENGARUH *CRYPTO FEAR AND GREED INDEX*
DALAM PREDIKSI HARGA BITCOIN MENGGUNAKAN
*MULTIVARIATE LONG SHORT-TERM MEMORY***

TUGAS AKHIR

WAHYUDIYANTO

121450040



ITERA


**PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2025**

**ANALISIS PENGARUH *CRYPTO FEAR AND GREED INDEX*
DALAM PREDIKSI HARGA BITCOIN MENGGUNAKAN
*MULTIVARIATE LONG SHORT-TERM MEMORY***

TUGAS AKHIR

Diajukan sebagai syarat untuk memperoleh gelar Sarjana

**WAHYUDIYANTO
121450040**



ITERA

**PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2025**

HALAMAN PENGESAHAN

Tugas Akhir Sarjana dengan judul "**Analisis Pengaruh *Crypto Fear and Greed Index* dalam Prediksi Harga Bitcoin Menggunakan *Multivariate Long Short-Term Memory***" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 09 Agustus 2025

Penulis,



WAHYUDIYANTO
NIM. 121450040

Diperiksa dan disetujui oleh,
Pembimbing I Pembimbing II

Mika Alvionita S., S.Si., M.Si.
NRK. 1993050920212258

Tirta Setiawan, S.Pd., M.Si.
NIP. 199008222022031003

Disahkan oleh,
Koordinator Program Studi Sains Data
Fakultas Sains
Institut Teknologi Sumatera

Tirta Setiawan, S.Pd., M.Si
NIP. 199008222022031003

Sidang Tugas Akhir:

Penguji I : Christyan Tamarro Nadeak, S.Si., M.Si.

Penguji II : Rohmi Dyah Astuti, S.Si., M.Cs.

HALAMAN PERNYATAAN ORISINALITAS

Skripsi ini adalah karya saya sendiri dan semua sumber baik yang dikutip maupun yang dirujuk telah saya nyatakan benar.

Nama : WAHYUDIYANTO

NIM : 121450040

Tanda tangan :

Tanggal : 09 Agustus 2025

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : WAHYUDIYANTO
NIM : 121450040
Program Studi : Sains Data
Fakultas : Sains
Jenis karya : Tugas Akhir

demikian pengembangan ilmu pengetahuan, menyetujui untuk memberikan Hak Bebas Royalti Noneksklusif (*Non-Exclusive Royalty Free Right*) kepada Institut Teknologi Sumatera atas karya ilmiah saya yang berjudul:

ANALISIS PENGARUH *CRYPTO FEAR AND GREED INDEX* DALAM PREDIKSI HARGA BITCOIN MENGGUNAKAN *MULTIVARIATE LONG SHORT-TERM MEMORY*

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/format-kan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan
Pada tanggal : 09 Agustus 2025

Yang menyatakan

WAHYUDIYANTO

ABSTRAK

ANALISIS PENGARUH *CRYPTO FEAR AND GREED INDEX* DALAM PREDIKSI HARGA BITCOIN MENGGUNAKAN *MULTIVARIATE LONG SHORT-TERM MEMORY*

WAHYUDIYANTO (121450040)

Pembimbing I: Mika Alvionita S., S.Si., M.Si.

Pembimbing II: Tirta Setiawan, S.Pd., M.Si.

Harga Bitcoin yang sangat fluktuatif menimbulkan tantangan dalam prediksi harga yang akurat, sehingga integrasi sentimen pasar menjadi penting untuk meningkatkan keandalan model prediksi. Penelitian ini mengkaji pengaruh *Crypto Fear and Greed Index* (FGI) dalam memprediksi harga Bitcoin menggunakan model *Multivariate Long Short-Term Memory* (LSTM). Data yang digunakan berupa harga harian Bitcoin (*open, high, low, close, volume*) dan nilai FGI periode 1 Februari 2018–30 Mei 2025. Dua model dikembangkan, yaitu Model 1 yang hanya menggunakan lima fitur internal harga dan Model 2 yang mengintegrasikan FGI beserta korelasi bulanan antara FGI dan komponen harga. Proses pelatihan model dilakukan dengan penyetelan *hyperparameter* menggunakan algoritma *Hyperband* dan penerapan *early stopping* dengan metrik objektif *Mean Squared Error* (MSE). Evaluasi kinerja model dilakukan pada data uji menggunakan *Mean Absolute Percentage Error* (MAPE). Hasil penelitian menunjukkan bahwa Model 2 mencapai nilai MAPE sebesar 2,33%, lebih rendah dibandingkan Model 1 dengan MAPE sebesar 6,02%. Temuan ini menegaskan bahwa integrasi sentimen pasar melalui FGI dan informasi korelasi bulanan mampu meningkatkan akurasi prediksi harga Bitcoin secara signifikan, serta memberikan implikasi positif bagi pengembangan sistem perdagangan otomatis yang lebih andal.

Kata kunci: Bitcoin, *Crypto Fear and Greed Index*, *Multivariate LSTM*, *Hyperband*, MAPE

ABSTRACT

The Influence of Crypto Fear and Greed Index in Bitcoin Price Prediction Using Multivariate Long Short-Term Memory

WAHYUDIYANTO (121450040)

Advisor I: Mika Alvionita S., S.Si., M.Si.

Advisor II: Tirta Setiawan, S.Pd., M.Si.

The highly volatile nature of Bitcoin prices presents a significant challenge for accurate price prediction, highlighting the importance of integrating market sentiment to improve the reliability of predictive models. This study investigates the influence of the Crypto Fear and Greed Index (FGI) in forecasting Bitcoin prices using a Multivariate Long Short-Term Memory (LSTM) model. The dataset includes daily Bitcoin price data (open, high, low, close, and volume) along with FGI values from February 1, 2018, to May 30, 2025. Two models were developed: Model 1, which utilizes only the five internal price features, and Model 2, which integrates FGI along with the monthly correlation between FGI and price components. Model training involved hyperparameter tuning using the Hyperband algorithm and the application of early stopping with the Mean Squared Error (MSE) as the objective metric. Model performance was evaluated on test data using the Mean Absolute Percentage Error (MAPE). The results show that Model 2 achieved a MAPE of 2.33%, significantly lower than Model 1's MAPE of 6.02%. These findings confirm that incorporating market sentiment through FGI and its monthly correlations can substantially enhance the accuracy of Bitcoin price predictions, offering positive implications for the development of more reliable automated trading systems.

Keywords: Bitcoin, Crypto Fear and Greed Index, Multivariate LSTM, Hyperband, MAPE

MOTTO

*"The best of people are those who are most beneficial to others."
(Hadith narrated by Ahmad, al-Tabarani, and al-Daraqutni)*

HALAMAN PERSEMBAHAN

*To my past self,
who endured every challenge,
and my future self,
who has achieved the dream.*

KATA PENGANTAR

Puji syukur ke hadirat Allah SWT atas limpahan rahmat dan hidayah-Nya sehingga skripsi ini dapat terselesaikan. Shalawat dan salam tercurah kepada Nabi Muhammad SAW.

Skripsi ini disusun untuk memenuhi salah satu syarat memperoleh gelar Sarjana pada Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera. Penulis mengucapkan terima kasih kepada semua pihak yang telah memberi dukungan, bantuan, dan doa selama proses penyusunan.

1. Kedua orang tua tercinta, Mama dan Tata, serta saudara-saudara tersayang Kak Ita, Kak Heri, Uni, Ikki, dan Dhirga, yang selalu memberikan doa, dukungan, dan semangat tanpa henti.
2. Ibu Mika Alvionita S., M.Si., selaku Dosen Pembimbing I sekaligus Dosen Wali, atas kesabaran, arahan, dan bimbingan yang sangat berarti selama proses penyusunan tugas akhir ini.
3. Bapak Tirta Setiawan, S.Pd., M.Si., selaku Dosen Pembimbing II, atas bantuan, masukan, dan motivasi yang diberikan kepada penulis.
4. Seluruh pihak yang senantiasa mendukung, di antaranya Arsyi, Afwa, Adit, saudara seperantauan Aulia, Aisyah, Widya, Husni, serta teman-teman dari Bansos yang tidak dapat disebutkan satu per satu.

Penulis menyadari skripsi ini masih jauh dari sempurna, sehingga kritik dan saran yang membangun sangat diharapkan. Semoga skripsi ini bermanfaat bagi pembaca dan menjadi amal jariyah bagi semua yang telah membantu.

Lampung Selatan, 09 Agustus 2025

Wahyudiyanto

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PENGESAHAN	ii
HALAMAN PERNYATAAN ORISINALITAS	iii
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI	iv
ABSTRAK	v
ABSTRACT	vi
MOTTO	vii
HALAMAN PERSEMBAHAN	viii
KATA PENGANTAR	ix
DAFTAR ISI	x
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiii
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	3
II TINJAUAN PUSTAKA	4
2.1 Penelitian Terdahulu	4
2.2 Bitcoin	4
2.3 <i>Crypto Fear and Greed Index</i> (FGI)	5
2.4 Korelasi Pearson	5
2.5 <i>Min-Max Scaler</i>	6
2.6 <i>Bobot</i>	7
2.7 <i>Sliding Window</i>	7
2.8 <i>Hyperparameter</i>	8
2.9 <i>Long Short-Term Memory</i> (LSTM)	12
2.9.1 <i>Forget Gate</i>	13

2.9.2	<i>Input Gate</i>	14
2.9.3	<i>Cell State Update</i>	14
2.9.4	<i>Output Gate</i>	15
2.10	<i>Multivariate Long Short-Term Memory (Multivariate LSTM)</i>	15
2.11	<i>Hyperband Hyperparameter Tuning</i>	16
2.12	Evaluasi Kinerja Model	18
2.12.1	<i>Mean Absolute Percentage Error (MAPE)</i>	18
III	METODE PENELITIAN	19
3.1	Deskripsi Data	19
3.2	Tahapan Penelitian	20
3.2.1	Pengumpulan Data	21
3.2.2	<i>Preprocessing</i>	21
3.2.3	Perancangan Arsitektur Model	22
3.2.4	<i>Hyperparameter Tuning</i>	22
3.2.5	Prediksi dan Evaluasi	23
IV	HASIL DAN PEMBAHASAN	24
4.1	Analisis Data Eksploratif	24
4.2	<i>Preprocessing</i> Data	27
4.2.1	Integrasi Data	27
4.2.2	Analisis Korelasi	28
4.2.2.1	Korelasi Global	28
4.2.2.2	Korelasi Per Bulan	29
4.2.3	<i>Feature Engineering</i>	31
4.2.4	Pembagian dan Normalisasi Data	32
4.3	Konfigurasi <i>Hyperparameter</i>	35
4.3.1	Konfigurasi dan Hasil Tuning Model 1	36
4.3.2	Konfigurasi dan Hasil Tuning Model 2	38
4.3.3	Analisis Distribusi Konfigurasi Terbaik	39
4.4	Struktur <i>Input</i>	40
4.5	Pelatihan Model	42
4.5.1	Evaluasi Kurva <i>Loss</i>	43
4.5.2	Analisis Konvergensi Bobot Jaringan	45

4.6	Evaluasi Hasil Prediksi	48
4.6.1	Analisis Hasil Evaluasi dengan MAPE	48
4.6.2	Analisis Hasil Prediksi	48
V	KESIMPULAN DAN SARAN	50
5.1	Kesimpulan	50
5.2	Saran	50
	DAFTAR PUSTAKA	52
	LAMPIRAN	57

DAFTAR GAMBAR

Gambar 2.1	Proses <i>sliding window</i>	7
Gambar 2.2	Kurva Fungsi Aktivasi Sigmoid	11
Gambar 2.3	Kurva Fungsi Aktivasi Tanh	12
Gambar 2.4	Struktur sel LSTM	13
Gambar 2.5	<i>Forget Gate</i>	13
Gambar 2.6	<i>Input Gate</i>	14
Gambar 2.7	<i>cell state</i>	14
Gambar 2.8	<i>Output Gate</i>	15
Gambar 2.9	<i>Input Multivariate LSTM (many to one)</i> . . .	16
Gambar 2.10	<i>Input Univariate LSTM (many to one)</i>	16
Gambar 3.1	Diagram alir penelitian	20
Gambar 4.1	Visualisasi Fitur Internal Bitcoin (2018–2025)	25
Gambar 4.2	Pergerakan Harga Penutupan Bitcoin dengan Pewarnaan Berdasarkan <i>Crypto Fear and Greed Index</i>	26
Gambar 4.3	Korelasi Per Bulan FGI terhadap Fitur Bitcoin	30
Gambar 4.4	Korelasi Per Bulan FGI terhadap <i>Volume</i> . . .	31
Gambar 4.5	Hasil Pembagian Data <i>Close</i> Setelah Normalisasi	34
Gambar 4.6	Struktur Tensor Optimal Model 1 (32, 14, 5) .	41
Gambar 4.7	Mekanisme <i>Sliding Window</i> Model 1 dengan <i>Sequence Length</i> 14	41
Gambar 4.8	Struktur Tensor Optimal Model 2 (64, 7, 11) .	42
Gambar 4.9	Mekanisme <i>Sliding Window</i> Model 2 dengan <i>Sequence Length</i> 7	42
Gambar 4.10	Kurva <i>Loss</i> Model 1.	44
Gambar 4.11	Kurva <i>Loss</i> Model 2.	45
Gambar 4.12	Konvergensi Bobot Jaringan Model 1	46
Gambar 4.13	Konvergensi Bobot Jaringan Model 2	47
Gambar 4.14	Prediksi Model 2 terhadap Data Uji (dengan FGI dan korelasi bulanan)	49

DAFTAR TABEL

Tabel 2.1	Ringkasan Penelitian Terkait Model Prediksi Harga Bitcoin	4
Tabel 3.1	Data Harga Bitcoin Harian	19
Tabel 3.2	Data <i>Crypto Fear & Greed Index</i> (FGI)	19
Tabel 3.3	Ruang Pencarian <i>Hyperparameter</i> untuk Model LSTM	22
Tabel 4.1	Struktur Data Gabungan Setelah Integrasi . . .	27
Tabel 4.2	Nilai Korelasi dan <i>P-value</i> antara FGI dan Fitur Harga Bitcoin	29
Tabel 4.3	Korelasi Per Bulan FGI terhadap Fitur Harga Bitcoin	31
Tabel 4.4	Perbandingan Fitur yang Digunakan pada Model 1 dan Model 2	32
Tabel 4.5	Pembagian Dataset Setelah Rekayasa Fitur . .	33
Tabel 4.6	Data Latih Setelah Normalisasi	34
Tabel 4.7	Data Validasi Setelah Normalisasi	34
Tabel 4.8	Data Uji Setelah Normalisasi	35
Tabel 4.9	Parameter Terbaik untuk Model 1	36
Tabel 4.10	Konfigurasi <i>Hyperparameter Tuning</i> Model 1	37
Tabel 4.11	Parameter Terbaik untuk Model 2	38
Tabel 4.12	Konfigurasi <i>Hyperparameter Tuning</i> Model 2	39
Tabel 4.13	Distribusi 50 Kombinasi <i>Hyperparameter</i> Terbaik untuk Kedua Model	40
Tabel 4.14	Ringkasan Arsitektur dan Jumlah Parameter Model	43
Tabel 4.15	Perbandingan Kinerja Final Model Berdasarkan Nilai MAPE	48

BAB I

PENDAHULUAN

1.1 Latar Belakang

Bitcoin adalah mata uang digital terdesentralisasi yang mengandalkan teknologi *blockchain* dan transaksi *peer-to-peer* untuk menjamin keamanan dan transparansi [1]. Namun, dibalik keunggulannya, harga Bitcoin sangat fluktuatif dan dipengaruhi oleh berbagai faktor eksternal. Fluktuasi harga yang tinggi ini menyulitkan prediksi harga secara akurat, yang pada akhirnya meningkatkan risiko bagi investor [2]. Oleh karena itu, mempertimbangkan sentimen pasar menjadi aspek penting dalam prediksi harga Bitcoin. Salah satu indikator yang digunakan untuk mengukur sentimen pasar kripto adalah *Crypto Fear and Greed Index* (FGI), yaitu indeks yang mencerminkan psikologi pasar berdasarkan sejumlah indikator seperti volatilitas, momentum, dominasi Bitcoin, aktivitas media sosial, dan tren pencarian Google [3]. Studi oleh Huang, Qichuan [4] menunjukkan bahwa meskipun korelasi global (keseluruhan rentang waktu) antara FGI dan harga Bitcoin secara umum rendah ($r \approx 0,3$), sebanyak 64-65% bulan pada periode 2018–2023, justru menunjukkan hubungan korelasi keduanya kuat secara temporal (per bulan). Temuan ini mengindikasikan bahwa relasi antara sentimen pasar dan harga Bitcoin bersifat dinamis dan bergantung pada konteks waktu tertentu [5].

Saat ini, eksplorasi terhadap variabel eksogen seperti FGI dalam model prediksi harga Bitcoin masih relatif jarang ditemukan dalam literatur [6]. Untuk menjawab celah tersebut, penelitian ini mengkaji penggunaan data historis harga Bitcoin dan FGI dalam membangun model prediksi berbasis Multivariate Long Short-Term Memory (LSTM). Model ini merupakan pengembangan dari *Recurrent Neural Network* (RNN) yang dirancang untuk menangkap hubungan *non-linear* serta ketergantungan temporal jangka panjang, dan memungkinkan integrasi banyak fitur sebagai input secara simultan. Studi oleh Htay, Ghahremani, dan Shiaeles [7] menunjukkan bahwa

penyertaan variabel sentimen dalam arsitektur *Multivariate LSTM* mampu meningkatkan akurasi prediksi secara signifikan dibandingkan dengan model *Univariate*. Selain itu, Scanlon, Quille, dan Jaiswal [8] membuktikan bahwa pendekatan ini secara konsisten mengungguli metode tradisional seperti *Autoregressive Integrated Moving Average* (ARIMA), RNN, dan *Artificial Neural Network* (ANN) dalam memprediksi harga Bitcoin. Mendukung temuan tersebut, penelitian oleh Gautam, Santra, Sharma, dkk. [9] yang mengembangkan model *hybrid LSTM-XGBoost* dengan integrasi skor sentimen dan indikator makroekonomi, juga terbukti mampu meningkatkan akurasi MAPE secara signifikan dibandingkan model-model tunggal pada data pasar kripto yang kompleks.

Dengan mempertimbangkan keunggulan *Multivariate LSTM* dalam menangkap interaksi kompleks antar fitur dan dinamika temporal, serta kemampuan FGI dalam merefleksikan psikologi pasar secara *real-time*, integrasi keduanya diharapkan dapat meningkatkan akurasi prediksi harga secara signifikan. Penelitian ini membangun dua model prediksi berbasis *Multivariate LSTM*, yakni model dengan penyertaan FGI dan model baseline tanpa FGI, guna mengevaluasi kontribusi variabel sentimen. Selain itu, penelitian ini mengusulkan pemanfaatan korelasi bulanan antara FGI dan lima fitur internal Bitcoin sebagai fitur tambahan untuk menangkap dinamika sentimen-harga secara lebih kontekstual. Pendekatan ini diperkuat oleh Agrawal dkk. [10], yang menunjukkan bahwa penambahan tensor korelasi antar indikator teknikal sebagai fitur input dalam LSTM menurunkan MAPE dari 1,76% menjadi 1,29%, menegaskan efektivitas informasi korelasi dalam meningkatkan akurasi prediksi. Selain itu, Choi [11] membuktikan bahwa koefisien korelasi antar aset bersifat dinamis dan dapat dimodelkan secara efektif dengan LSTM, bahkan saat korelasi menjadi target prediksi. Kedua temuan ini memperkuat relevansi integrasi korelasi jangka pendek, seperti korelasi bulanan, dalam membentuk representasi temporal yang adaptif dalam model prediksi deret waktu.

1.2 Rumusan Masalah

Berdasarkan latar belakang dan permasalahan yang telah diuraikan, penelitian ini dirancang untuk menjawab permasalahan utama sebagai berikut:

1. Bagaimana perancangan model prediksi harga Bitcoin berbasis *Multivariate Long Short-Term Memory* (LSTM) yang mengintegrasikan data historis harga dengan indikator sentimen pasar *Crypto Fear and Greed Index* (FGI)?
2. Sejauh mana penyertaan FGI beserta fitur korelasi bulanan terhadap variabel harga meningkatkan akurasi prediksi dibandingkan model berbasis data historis saja?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah di atas, penelitian ini bertujuan untuk:

1. Merancang dan mengimplementasikan model prediksi harga Bitcoin berbasis *Multivariate LSTM* yang mengintegrasikan data historis harga dengan FGI serta fitur korelasi bulanan antara FGI dan komponen harga.
2. Menganalisis dampak penyertaan FGI dan korelasinya terhadap akurasi prediksi dengan evaluasi kinerja menggunakan *Mean Absolute Percentage Error* (MAPE).

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Tabel berikut merangkum beberapa penelitian relevan yang menjadi acuan dalam studi ini.

Tabel 2.1 Ringkasan Penelitian Terkait Model Prediksi Harga Bitcoin

Judul Penelitian	Peneliti, Tahun	Metode	Hasil
<i>Enhancing Bitcoin Price Prediction with Deep Learning: Integrating Social Media Sentiment and Historical Data</i> [7]	Hla Soe Htay, Mani Ghahremani, Stavros Shiaeles, 2025	<i>Multivariate</i> LSTM + Sentimen Twitter	Model dengan sentimen Twitter terbukti paling unggul dari lima model yang diuji, mencapai MAE = 0.00196 dan RMSE = 0.00304.
<i>Optimizing Bitcoin Price Prediction: Multivariate LSTM Triumphs</i> [8]	Brian Scanlon, Keith Quille, Rajesh Jaiswal, 2025	<i>Multivariate</i> LSTM	Dengan input sentimen (Google Trends, frekuensi tweet) dan data ekonomi (USD, Emas, VIX), model terbukti mengungguli RNN, SVR, ANN, dan ARIMA dengan RMSE = 268.83.
<i>A Multivariate LSTM-Based Deep Learning Model for Stock Market Prediction</i> [12]	Samuel Ibukun Olotu, 2023	<i>Multivariate</i> LSTM	Dalam konteks prediksi pasar saham, model <i>Multivariate</i> LSTM yang menggunakan data harga historis menunjukkan kinerja yang lebih baik dibandingkan metode tradisional dan DL lainnya.

2.2 Bitcoin

Bitcoin merupakan aset kripto pertama yang diperkenalkan oleh Satoshi Nakamoto pada tahun 2008 sebagai sistem mata uang digital terdesentralisasi berbasis *peer-to-peer*, yang memungkinkan transaksi tanpa perantara [1]. Sistem ini berjalan di atas teknologi *blockchain* dan menggunakan mekanisme konsensus *Proof-of-Work* untuk memverifikasi dan mencatat transaksi secara permanen. Karakteristik

seperti desentralisasi, transparansi, dan keterbatasan suplai hingga 21 juta unit menjadikan Bitcoin menarik sebagai aset alternatif dan sering disebut sebagai “emas digital”. Namun, sifat pasar kripto yang tidak terpusat, beroperasi 24/7, dan sangat dipengaruhi oleh faktor spekulatif serta sentimen publik menyebabkan volatilitas harga Bitcoin sangat tinggi, dapat mencapai sepuluh kali lipat dibanding mata uang fiat [13].

2.3 *Crypto Fear and Greed Index (FGI)*

Crypto Fear and Greed Index (FGI) adalah indikator sentimen pasar kripto yang mengukur emosi kolektif investor, dari ketakutan hingga keserakahan, dalam skala 0–100. FGI tersusun atas enam komponen utama, yaitu volatilitas (25%), volume (25%), media sosial (15%), survei (15%), dominasi Bitcoin (10%), dan tren pencarian (10%) [14]. Indeks ini mencerminkan peran emosi dalam volatilitas pasar. Nilai FGI dikelompokkan ke dalam lima kategori utama, yaitu *Extreme Fear* (0–24), *Fear* (25–49), *Neutral* (50), *Greed* (51–74), dan *Extreme Greed* (75–100) [15].

2.4 Korelasi Pearson

Korelasi Pearson mengukur kekuatan dan arah hubungan linier antara dua variabel numerik. Nilai koefisien korelasi r berada dalam rentang -1 hingga +1. Nilai r positif menunjukkan hubungan searah, sedangkan nilai negatif menunjukkan hubungan berlawanan arah. Korelasi dianggap signifikan secara statistik apabila nilai p -value $< 0,05$ [16]. Koefisien korelasi Pearson dihitung menggunakan Persamaan 2.1 berikut:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.1)$$

Keterangan:

- r : Koefisien korelasi Pearson,
- x_i, y_i : Data ke- i dari variabel x dan y ,
- \bar{x}, \bar{y} : Rata-rata dari variabel x dan y ,

n : Jumlah pasangan data.

Untuk menguji signifikansi statistik dari nilai r , digunakan uji t dengan derajat kebebasan $(n - 2)$ menggunakan Persamaan 2.2:

$$t = \frac{r \sqrt{n - 2}}{\sqrt{1 - r^2}} \quad (2.2)$$

Keterangan:

t : Nilai statistik t untuk uji signifikansi,

r : Koefisien korelasi Pearson,

n : Jumlah pasangan data.

Nilai t kemudian digunakan untuk menghitung p -value berdasarkan distribusi t -Student dua sisi dengan derajat kebebasan $(n - 2)$. Jika p -value $< 0,05$, maka hubungan antara kedua variabel dianggap signifikan secara statistik.

2.5 Min-Max Scaler

Min-Max Scaler merupakan metode normalisasi yang digunakan untuk mengubah skala data ke dalam rentang tertentu, biasanya antara 0 dan 1. Normalisasi dilakukan agar skala data pada setiap fitur sama sehingga model dapat belajar secara optimal [17]. Proses normalisasi dilakukan menggunakan Persamaan 2.3 berikut:

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (2.3)$$

Keterangan:

X_{norm} : Nilai hasil normalisasi,

X : Nilai asli dari data,

X_{\min} : Nilai minimum dalam data,

X_{\max} : Nilai maksimum dalam data.

Inverse transform adalah metode untuk mengembalikan data yang telah dinormalisasi ke skala aslinya agar hasil prediksi dapat diterjemahkan ke dalam skala aslinya [17]. Rumusnya ditunjukkan pada Persamaan 2.4 berikut:

$$X = X_{\text{norm}} \cdot (X_{\text{max}} - X_{\text{min}}) + X_{\text{min}} \quad (2.4)$$

Keterangan:

X : Nilai asli dari data, hasil *inverse transform*,

X_{norm} : Nilai hasil prediksi yang telah dinormalisasi,


$X_{\text{min}}, X_{\text{max}}$: Nilai minimum dan maksimum.

2.6 Bobot

Bobot (*weight*) adalah parameter internal pada neuron yang menentukan seberapa besar pengaruh setiap input terhadap output. Dalam konteks pembelajaran mesin, proses pelatihan bertujuan menemukan nilai bobot yang optimal agar model dapat memetakan input ke output secara akurat. Bobot diperbarui secara bertahap menggunakan algoritma *optimizer* berdasarkan nilai gradien dari fungsi kerugian [18].

2.7 Sliding Window

Sliding window menyusun data deret waktu menjadi pasangan *input-output* untuk pelatihan model. Setiap sampel terdiri dari sejumlah data historis sepanjang t hari sebagai *input* (X), dan nilai pada hari berikutnya sebagai target (Y). Seperti ditunjukkan pada Gambar 2.1, jendela digeser satu langkah untuk menghasilkan sampel berikutnya secara berurutan hingga seluruh data terpenuhi [19].



Gambar 2.1 Proses *sliding window*

2.8 Hyperparameter

Hyperparameter merupakan parameter konfigurasi eksternal yang nilainya ditetapkan sebelum proses pelatihan model dimulai. Parameter ini tidak dipelajari secara langsung oleh model dari data, melainkan mengontrol bagaimana model belajar. Pemilihan *hyperparameter* yang tepat sangat krusial untuk mencapai performa model yang optimal [18]. Dalam pengembangan model *deep learning*, terdapat sejumlah hyperparameter utama yang secara umum memengaruhi performa model. Beberapa di antaranya adalah sebagai berikut:

1. *Sequence Length*

Sequence length adalah jumlah langkah waktu historis yang digunakan model untuk memprediksi nilai di masa depan. Pemilihannya memengaruhi kemampuan model dalam menangkap pola jangka pendek maupun panjang [18].

2. Jumlah Lapisan LSTM

Jumlah lapisan LSTM mengacu pada banyaknya lapisan LSTM yang ditumpuk secara vertikal. Menambah jumlah lapisan dapat memungkinkan model untuk mempelajari representasi data yang lebih kompleks dan hierarkis, namun juga meningkatkan risiko *overfitting* dan beban komputasi [18].

3. Neuron

Neuron merupakan unit komputasi dasar dalam jaringan saraf tiruan, termasuk pada arsitektur *LSTM*. Setiap *neuron* menerima satu atau lebih sinyal masukan, mengalikannya dengan *weight*, menambahkan *bias*, lalu menerapkan fungsi aktivasi non-linear untuk menghasilkan keluaran. Sekumpulan *neuron* membentuk lapisan tersembunyi yang mampu merepresentasikan pola kompleks secara hierarkis, sehingga memungkinkan jaringan mempelajari hubungan non-linier dari data [18].

4. *Dropout Rate*

Dropout adalah teknik regularisasi yang secara acak menonaktifkan sebagian *neuron* dan koneksinya saat pelatihan,

guna mencegah *overfitting*. Pendekatan ini memaksa model belajar representasi yang lebih umum dan tidak bergantung pada jalur aktivasi tertentu. Dengan demikian, *dropout* meningkatkan kemampuan generalisasi jaringan terhadap data yang belum pernah dilihat [20].

5. *Kernel Regularization* (L_2)

Regularisasi L_2 adalah teknik yang menambahkan penalti terhadap besarnya bobot (*weights*) ke dalam fungsi kerugian, dengan tujuan mencegah model memiliki parameter yang terlalu besar dan kompleks. Penalty ini berbentuk jumlah kuadrat bobot, yang mendorong nilai bobot menuju nol tanpa benar-benar mengeliminasi fitur. Dengan demikian, L_2 regularisasi membantu menekan varians, meningkatkan kemampuan generalisasi, dan mengurangi risiko *overfitting*, terutama saat model dilatih pada data yang terbatas [18]. Rumus regularisasi L_2 untuk fungsi kerugian *Mean Squared Error* (MSE) ditunjukkan pada Persamaan 2.5.

$$L_{total} = \text{MSE} + \lambda \sum_i w_i^2 \quad (2.5)$$

Keterangan:

L_{total} : Fungsi kerugian total setelah regularisasi,

λ : Koefisien regularisasi,

w_i : Bobot model yang dikenai penalti.

6. *Optimizer*

Optimizer adalah algoritma yang memperbarui bobot jaringan saraf untuk meminimalkan fungsi kerugian [21]. Pemilihan optimizer yang tepat berpengaruh besar terhadap efisiensi dan hasil pelatihan model.

(a) RMSprop

Root Mean Square Propagation (RMSprop) menyesuaikan *learning rate* untuk setiap parameter menggunakan rata-rata pergerakan eksponensial dari gradien kuadrat. Pendekatan ini membantu mempercepat konvergensi,

terutama pada data yang bersifat non-stasioner [22].

(b) Adam

Adaptive Moment Estimation (Adam) menggabungkan prinsip RMSprop dan momentum dengan menghitung dua jenis rata-rata pergerakan, yaitu gradien (momen pertama) dan gradien kuadrat (momen kedua). Adam dikenal efisien secara komputasi dan sering memberikan hasil baik dengan sedikit penyetelan *hyperparameter* [21].

7. *Learning Rate*

Learning rate adalah *hyperparameter* yang menentukan besarnya langkah dalam pembaruan bobot pada setiap iterasi pelatihan. Nilai *learning rate* yang terlalu kecil akan memperlambat proses pelatihan, sedangkan nilai yang terlalu besar dapat menyebabkan ketidakstabilan model dan menghambat konvergensi [23].

8. *Batch Size*, Iterasi, dan *Epoch*

Batch size adalah jumlah sampel data yang diproses sekaligus sebelum bobot jaringan diperbarui. Satu iterasi mengacu pada satu kali pembaruan bobot berdasarkan satu *batch*. Sementara itu, satu *epoch* adalah satu siklus penuh di mana seluruh dataset pelatihan telah digunakan sekali untuk melatih model. Pelatihan umumnya dilakukan dalam beberapa *epoch* untuk memungkinkan model menyerap pola dari data secara bertahap [18]. *Epoch* maksimum yang digunakan dalam pencarian *hyperparameter* ini adalah 150.

9. *Early Stopping*

Early stopping adalah teknik untuk mencegah *overfitting* dengan menghentikan pelatihan saat performa pada data validasi tidak lagi membaik setelah beberapa *epoch* (*patience*). Bobot terbaik dari *epoch* sebelumnya akan disimpan sebagai model akhir, sehingga model tidak belajar berlebihan dari *noise* [24].

10. Fungsi Aktivasi

Fungsi aktivasi memungkinkan jaringan saraf untuk mempelajari pola *non-linier* yang kompleks. Tanpa fungsi aktivasi, sebuah

model hanya akan mampu membentuk pemetaan linier, terlepas dari jumlah lapisan yang dimilikinya, sehingga membatasi kemampuannya secara signifikan [23]. Dalam arsitektur *Long Short-Term Memory* (LSTM), dua fungsi aktivasi utama yang digunakan adalah Sigmoid dan Tanh (*Hyperbolic Tangent*).

(a) Fungsi Sigmoid

Fungsi aktivasi Sigmoid, yang juga dikenal sebagai fungsi logistik, memetakan nilai input numerik ke dalam rentang antara 0 dan 1. Karena outputnya dapat diinterpretasikan sebagai probabilitas, fungsi ini secara historis populer digunakan pada lapisan output untuk masalah klasifikasi biner [25]. Rumus matematis untuk fungsi Sigmoid dinyatakan dalam Persamaan 2.6.


$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (2.6)$$

Keterangan:

$\sigma(x)$: *Output* fungsi Sigmoid,

x : *Input linear* dari neuron.

Kurva fungsi Sigmoid ditampilkan pada Gambar 2.2, yang memperlihatkan bahwa *output* fungsi ini selalu berada pada rentang (0, 1), dengan transisi yang halus.



Gambar 2.2 Kurva Fungsi Aktivasi Sigmoid

(b) Fungsi Tanh (*Hyperbolic Tangent*)

Fungsi aktivasi Tanh (*hyperbolic tangent*) adalah fungsi non-linear yang memetakan nilai input ke dalam rentang antara -1 dan 1. Fungsi ini pada dasarnya adalah versi dari

fungsi Sigmoid yang telah diskalakan dan digeser sehingga berpusat di nol (*zero-centered*). Sifat *zero-centered* ini sering kali membuat konvergensi model lebih cepat dibandingkan Sigmoid [26]. Persamaan matematis fungsi Tanh diberikan pada Persamaan 2.7.


$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} = 2\sigma(2x) - 1 \quad (2.7)$$

Keterangan:

$\tanh(x)$: *Output fungsi Tanh*,

$\sigma(x)$: Fungsi Sigmoid.


Gambar 2.3 memperlihatkan bentuk kurva fungsi Tanh, yang simetris terhadap titik origin dan memungkinkan gradien yang lebih seimbang selama proses *backpropagation*, terutama pada lapisan-lapisan tersembunyi dari jaringan saraf.



Gambar 2.3 Kurva Fungsi Aktivasi Tanh

2.9 Long Short-Term Memory (LSTM)


Long Short-Term Memory (LSTM) adalah arsitektur dalam *Recurrent Neural Network* (RNN) yang dikembangkan oleh Hochreiter dan Schmidhuber pada 1997 untuk mengatasi masalah *vanishing gradient* dalam RNN klasik [27]. LSTM dirancang untuk memproses data sekuensial dengan memanfaatkan *cell state* dan sejumlah *gate* sebagai pengendali aliran informasi [28]. Struktur internal sel LSTM ditunjukkan pada Gambar 2.4.



Gambar 2.4 Struktur sel LSTM

Masing-masing komponen utama dalam sel LSTM dijelaskan sebagai berikut [12].

2.9.1 *Forget Gate*



Gambar 2.5 *Forget Gate*


Gambar 2.5 menunjukkan bagaimana *Forget Gate* menentukan informasi dari memori sebelumnya (C_{t-1}) yang perlu dilupakan. Nilai *gate* ini dihitung dengan fungsi sigmoid terhadap gabungan *input* saat ini (x_t) dan *hidden state* sebelumnya (h_{t-1}), sebagaimana ditunjukkan pada Persamaan 2.8.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.8)$$

Keterangan:

- f_t : Nilai *Forget Gate* pada waktu t ,
- x_t : *Input* pada waktu t ,
- h_{t-1} : *Hidden state* sebelumnya,
- W_f : Bobot *input Forget Gate*,
- b_f : Bias *Forget Gate*,
- σ : Fungsi aktivasi sigmoid.

2.9.2 Input Gate



Gambar 2.6 Input Gate

Gambar 2.6 menggambarkan bagaimana *Input Gate* menentukan informasi baru yang akan disimpan dalam memori sel. Proses ini terdiri dari dua tahap: menghitung nilai *gate* i_t dan menghasilkan kandidat nilai memori \tilde{C}_t , ditunjukkan pada Persamaan 2.9 dan 2.10.


$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.9)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.10)$$

Keterangan:

- i_t : Nilai *Input Gate* pada waktu t ,
- \tilde{C}_t : Kandidat nilai memori baru,
- W_i, W_c : Bobot untuk *Input Gate* dan kandidat memori,
- b_i, b_c : Bias untuk masing-masing,
- \tanh : Fungsi aktivasi *Hyperbolic Tangent*.

2.9.3 Cell State Update



Gambar 2.7 cell state

Gambar 2.7 memperlihatkan bagaimana memori sel diperbarui dengan menggabungkan informasi lama dan baru melalui hasil dari *Forget Gate* dan *Input Gate*. Hal ini dirumuskan pada Persamaan 2.11.


$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (2.11)$$

Keterangan:

C_t : Nilai memori sel pada waktu t ,

\odot : Perkalian elemen-per-elemen.

2.9.4 Output Gate



Gambar 2.8 Output Gate

Gambar 2.8 menunjukkan bagaimana *Output Gate* menentukan informasi apa yang akan dikeluarkan dari sel memori sebagai *hidden state* (h_t). Proses ini melibatkan dua tahap, yaitu aktivasi dari *gate* o_t dan pembobotan terhadap memori terkini C_t menggunakan fungsi aktivasi *tanh*. Persamaan matematisnya ditunjukkan pada Persamaan 2.12 dan 2.13.

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.12)$$

$$h_t = o_t \odot \tanh(C_t) \quad (2.13)$$

Keterangan:

o_t : Nilai *Output Gate* pada waktu t ,

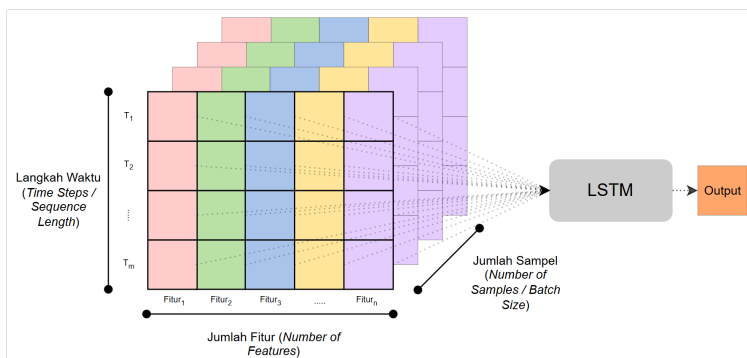
h_t : *Hidden State* pada waktu t ,

W_o, b_o : Bobot dan bias untuk *Output Gate*.

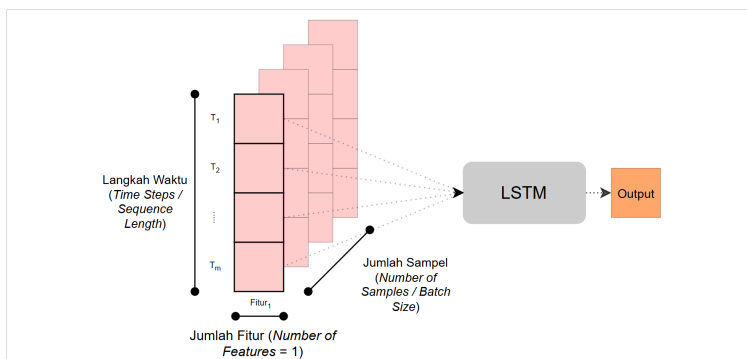
2.10 Multivariate Long Short-Term Memory (Multivariate LSTM)

Multivariate LSTM merupakan perluasan dari arsitektur LSTM yang dirancang untuk memproses data deret waktu dengan lebih dari satu fitur pada setiap langkah waktu. Dengan menerima vektor *input* berdimensi lebih dari satu ($n > 1$), arsitektur ini mampu menangkap

pola temporal serta interaksi antar fitur secara simultan [29]. Struktur internal selnya identik dengan LSTM standar, namun perbedaannya terletak pada bentuk tensor *input* yang digunakan [30]. Ilustrasi perbandingan antara *input Multivariate* dan *Univariate* LSTM ditunjukkan pada Gambar 2.9 dan 2.10.



Gambar 2.9 *Input Multivariate LSTM (many to one)*



Gambar 2.10 *Input Univariate LSTM (many to one)*

2.11 Hyperband Hyperparameter Tuning

Beberapa *hyperparameter* penting yang umum disetel dalam model *Long Short-Term Memory* (LSTM) meliputi *sequence length*, jumlah lapisan LSTM, jumlah neuron per lapisan, *dropout rate*, *kernel regularization*, jenis *optimizer*, *learning rate*, *batch size*, dan jumlah *epoch* maksimum. Penyetelan nilai-nilai tersebut berperan besar dalam menentukan kapasitas memori jangka panjang, kemampuan generalisasi, serta efisiensi pembelajaran model. Untuk

mengoptimalkan kombinasi parameter ini secara efisien, salah satu metode yang dapat digunakan adalah Hyperband, yakni algoritma yang menggabungkan pemilihan konfigurasi secara acak dan eliminasi bertahap berdasarkan kinerja awal melalui mekanisme *successive halving* [31].

Algorithm 1: *Pseudocode* Algoritma Hyperband

Input: R (sumber daya maksimum), η (faktor eliminasi, default: 3)

$s_{max} \leftarrow \lfloor \log_{\eta}(R) \rfloor$, $B \leftarrow (s_{max} + 1) \cdot R$;

for $s = s_{max}, s_{max} - 1, \dots, 0$ **do**

$n \leftarrow \lceil \frac{B}{R} \cdot \frac{\eta^s}{s+1} \rceil$;

$r \leftarrow R \cdot \eta^{-s}$;

$T \leftarrow$ Ambil n konfigurasi *hyperparameter* acak;

for $i = 0$ **to** s **do**

$n_i \leftarrow \lfloor n \cdot \eta^{-i} \rfloor$;

$r_i \leftarrow r \cdot \eta^i$;

Latih semua n_i konfigurasi selama r_i sumber daya;

Pilih $\lfloor n_i/\eta \rfloor$ konfigurasi terbaik untuk iterasi berikutnya;

end

end

return konfigurasi dengan *validation loss* terendah;

Keterangan:

R : Total sumber daya maksimum (misalnya, jumlah *epoch*),

η : Faktor eliminasi konfigurasi (default = 3),

s : Indeks *bracket*,

B : Total anggaran sumber daya dalam satu *bracket*,

n : Konfigurasi awal pada *bracket* ke- s ,

r : Sumber daya awal per konfigurasi,

n_i : Jumlah konfigurasi pada iterasi- i ,

r_i : Sumber daya per konfigurasi pada iterasi- i .

2.12 Evaluasi Kinerja Model

2.12.1 *Mean Absolute Percentage Error (MAPE)*

Evaluasi kinerja dalam studi prediksi dilakukan untuk mengukur tingkat akurasi model dalam merepresentasikan pola data aktual. Salah satu metrik evaluasi yang paling umum digunakan adalah *Mean Absolute Percentage Error (MAPE)*, karena memberikan interpretasi kesalahan dalam bentuk persentase yang bersifat skala-independen dan mudah dipahami. Model dengan nilai MAPE di bawah 10% umumnya dianggap memiliki akurasi yang sangat baik [32]. Rumus perhitungan MAPE ditunjukkan pada Persamaan 2.14:

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right| \times 100\% \quad (2.14)$$

Keterangan:

MAPE : Persentase kesalahan rata-rata,

n : Jumlah observasi,

Y_t : Nilai aktual,

\hat{Y}_t : Nilai prediksi.

BAB III

METODE PENELITIAN

3.1 Deskripsi Data

Penelitian ini menggunakan data harian harga Bitcoin dan indeks *Crypto Fear and Greed Index* (FGI) dari 1 Februari 2018 hingga 30 Mei 2025, periode yang dipilih berdasarkan ketersediaan data FGI dari *API Alternative.me*. Data harga Bitcoin terdiri dari lima fitur utama (*open, high, low, close, volume*) yang diperoleh melalui pustaka *yfinance*, sedangkan FGI direpresentasikan dalam skala 0–100 untuk mencerminkan sentimen pasar, dengan nilai rendah menandakan *fear* dan tinggi menandakan *greed*. Ringkasan data ditampilkan pada Tabel 3.1 dan Tabel 3.2.

Tabel 3.1 Data Harga Bitcoin Harian

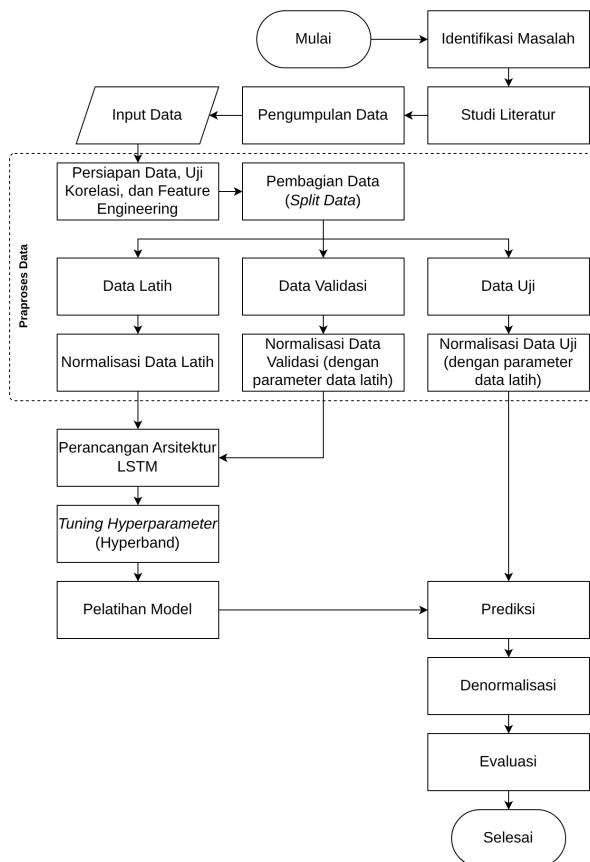
<i>Date</i>	<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>
31/05/2025	103994.72	104927.10	103136.12	104638.09	38997843858
30/05/2025	105646.21	106308.95	103685.79	103998.57	57655287183
29/05/2025	107795.57	108910.05	105374.40	105641.76	56022752042
28/05/2025	108992.17	109298.29	106812.93	107802.33	49155377493
...
04/02/2018	8277.01	9334.87	8031.22	9175.70	7073549824
03/02/2018	9174.91	9430.75	8251.63	8852.12	7263790080
02/02/2018	9142.28	9142.28	7796.49	8830.75	12726899712
01/02/2018	9170.54	10288.80	8812.28	10237.30	9959400448

Tabel 3.2 Data *Crypto Fear & Greed Index* (FGI)

<i>Date</i>	<i>Nilai FGI</i>
31/05/2025	50
30/05/2025	60
29/05/2025	74
28/05/2025	71
...	...
04/02/2018	24
03/02/2018	40
02/02/2018	15
01/02/2018	30

3.2 Tahapan Penelitian

Penelitian ini membangun model prediksi harga Bitcoin berbasis *Multivariate LSTM* secara sistematis, sebagaimana ditunjukkan pada Gambar 3.1. Proses dimulai dari identifikasi masalah dan studi literatur, dilanjutkan dengan pengumpulan dan persiapan data, termasuk uji korelasi dan *feature engineering*. Data dibagi menjadi data latih, validasi, dan uji, lalu dinormalisasi dengan parameter dari data latih. Selanjutnya, dilakukan perancangan arsitektur LSTM dan *hyperparameter tuning* dengan Hyperband, diikuti pelatihan model, prediksi, denormalisasi hasil, serta evaluasi kinerja model.



Gambar 3.1 Diagram alir penelitian

3.2.1 Pengumpulan Data

Penelitian ini menggunakan data harian harga Bitcoin (*open*, *high*, *low*, *close*, dan *volume*) yang diunduh melalui *library yfinance*, serta nilai harian *Crypto Fear and Greed Index* (FGI) dari API *alternative.me*, keduanya mencakup periode 1 Februari 2018 hingga 30 Mei 2025.

3.2.2 Preprocessing

Tahapan *preprocessing* merupakan proses penting untuk memastikan kualitas data sebelum dimasukkan ke dalam model. Pada tahap ini dilakukan integrasi, rekayasa fitur, serta pembagian dan normalisasi data agar model *Multivariate LSTM* dapat belajar secara optimal dari deret waktu yang bersih dan terstruktur.

1. Integrasi Data

Data dikonversi ke format waktu yang sesuai, lalu dianalisis secara statistik dan visual untuk memahami pola pergerakan Bitcoin dan FGI. Uji korelasi Pearson menunjukkan hubungan linier global yang lemah ($r \approx 0,3$), namun analisis perbulan mengungkap korelasi yang lebih bervariasi dan kontekstual. Untuk menangkap dinamika ini tanpa menambah kompleksitas model, ditambahkan fitur baru berupa korelasi perbulan FGI terhadap masing-masing fitur internal melalui proses *feature engineering*.

2. Feature Engineering

Rekayasa fitur dilakukan berdasarkan dinamika korelasi antara indeks FGI dan fitur internal Bitcoin pada Model 2. Fitur ini ditambahkan ke dalam dataset sebagai variabel statis per bulan yang diasosiasikan ke setiap baris data harian sesuai bulan masing-masing. Dengan demikian, model dapat menangkap pengaruh lokal FGI terhadap pergerakan harga tanpa eksplisit menambah dimensi temporal yang kompleks.

3. Pembagian dan Normalisasi Data

Data dipisahkan secara kronologis menjadi tiga bagian: data latih (70%), validasi (10%), dan uji (20%). Pembagian

dilakukan tanpa pengacakan agar urutan waktu tetap terjaga, memungkinkan model belajar pola temporal secara akurat. Setelah pembagian, dilakukan normalisasi menggunakan *MinMaxScaler*, di mana parameter skala diperoleh dari data latih. Parameter ini kemudian digunakan untuk mentransformasikan data validasi dan data uji agar konsistensi skala antar set data tetap terjaga.

3.2.3 Perancangan Arsitektur Model

Penelitian ini membandingkan dua model prediksi harga Bitcoin. Model pertama menggunakan lima fitur internal Bitcoin, sedangkan model kedua menambahkan *Fear and Greed Index* (FGI) dan lima fitur korelasi bulanan, sehingga totalnya sebelas fitur *input*. Keduanya menggunakan arsitektur *many-to-one* dengan satu atau lebih lapisan *LSTM*, *dropout*, dan *dense* linear sebagai *output*. Data diubah ke format sekuensial menggunakan *sliding window* dengan panjang urutan (*sequence length*) sebagai *hyperparameter* yang diuji pada nilai 7, 14, dan 21 hari. Setiap sekuens digunakan untuk memprediksi harga penutupan (*Close*) Bitcoin pada hari berikutnya.

3.2.4 Hyperparameter Tuning

Proses tuning dilakukan menggunakan algoritma *Hyperband* dengan metrik objektif *Mean Squared Error* pada data validasi. Teknik *early stopping* dengan *patience* 20 *epoch* digunakan untuk menghentikan pelatihan jika tidak ada peningkatan performa. Ruang pencarian *hyperparameter* diadaptasi dari penelitian terdahulu oleh Michańków, *et al.* [33]. *Hyperparameter* yang diuji ditunjukkan pada Tabel 3.3.

Tabel 3.3 Ruang Pencarian *Hyperparameter* untuk Model LSTM

<i>Hyperparameter</i>	Ruang Pencarian
<i>Sequence length</i>	7, 14, 21
Jumlah lapisan LSTM	1, 2, 3
Jumlah neuron per lapisan	64, 96, 128
<i>Dropout rate</i>	0.01, 0.1, 0.2

<i>Kernel regularization</i>	0.0001, 0.001, 0.01
<i>Optimizer</i>	RMSProp, Adam
<i>Learning rate</i>	0.001, 0.01, 0.1
<i>Batch size</i>	32, 64, 128
<i>Epoch maksimum</i>	150

3.2.5 Prediksi dan Evaluasi

Setelah model dilatih secara penuh menggunakan data latih, proses prediksi dilakukan terhadap data uji yang belum pernah dilihat oleh model. Karena hasil prediksi dan nilai aktual berada dalam skala ternormalisasi, maka perlu dilakukan denormalisasi menggunakan metode *inverse transform* agar nilai harga penutupan kembali ke skala aslinya dan dapat dianalisis secara mendalam. Evaluasi kinerja dilakukan terhadap data uji menggunakan metrik *Mean Absolute Percentage Error* (MAPE), yang mengukur rata-rata kesalahan absolut dalam bentuk persentase terhadap nilai aktual.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Analisis Data Eksploratif

Penelitian ini menggunakan data harian harga Bitcoin dan *Crypto Fear and Greed Index* (FGI) dari 1 Februari 2018 hingga 30 Mei 2025. Periode ini dipilih karena data FGI tersedia mulai dari tanggal tersebut melalui situs *Alternative.me*. Data harga Bitcoin diperoleh menggunakan pustaka *yfinance*, yang mencakup harga pembukaan (*open*), tertinggi (*high*), terendah (*low*), penutupan (*close*), dan volume transaksi. *Crypto Fear and Greed Index* (FGI) merupakan indikator kuantitatif yang merepresentasikan sentimen pasar kripto dalam rentang nilai 0 hingga 100, di mana nilai yang lebih rendah mencerminkan dominasi sentimen ketakutan (*fear*), sedangkan nilai yang lebih tinggi mengindikasikan sentimen keserakahan (*greed*). Kedua data yang digunakan dalam penelitian ini tidak mengandung nilai kosong (*missing value*) dan telah siap untuk dianalisis sebagai deret waktu.

Untuk memahami dinamika masing-masing fitur internal Bitcoin, Gambar 4.1 menyajikan visualisasi kelima fitur tersebut dalam format sub-gambar, meliputi harga pembukaan (*Open*), harga tertinggi (*High*), harga terendah (*Low*), harga penutupan (*Close*), dan volume perdagangan harian. Dari visualisasi tersebut, dapat diamati bahwa seluruh fitur harga menunjukkan pola pergerakan yang saling berkorelasi dan mengikuti tren yang relatif serupa, meskipun dengan nilai absolut yang berbeda. Volume perdagangan cenderung meningkat secara signifikan pada periode volatilitas tinggi, terutama selama bull market dan saat krisis pasar terjadi.



(a) Harga Penutupan (*Close*)



(b) Harga Tertinggi (*High*)



(c) Harga Terendah (*Low*)



(d) Harga Pembukaan (*Open*)



(e) Volume Perdagangan Harian

Gambar 4.1 Visualisasi Fitur Internal Bitcoin (2018–2025)

Selanjutnya, untuk mengkaji hubungan antara harga penutupan Bitcoin dan sentimen pasar, Gambar 4.2 menampilkan visualisasi harga *Close* Bitcoin yang diwarnai berdasarkan nilai FGI. Titik-titik pada grafik diberi gradasi warna dari ungu gelap (*Extreme Fear*) hingga kuning terang (*Extreme Greed*) sesuai dengan nilai indeks pada setiap harinya.



Gambar 4.2 Pergerakan Harga Penutupan Bitcoin dengan Pewarnaan Berdasarkan *Crypto Fear and Greed Index*

Dari visualisasi ini, dapat diamati bahwa perubahan warna titik-titik FGI cenderung mengikuti atau bahkan mendahului fluktuasi harga Bitcoin yang tajam. Selama periode tekanan pasar seperti krisis COVID-19 (Maret 2020), krisis Terra-LUNA (Mei 2022), dan kejatuhan FTX (November 2022), FGI bergerak ke zona *Extreme Fear* yang ditandai dengan pewarnaan ungu tua. Penurunan tajam harga Bitcoin pada periode tersebut disertai dengan peningkatan volume perdagangan, menunjukkan reaksi pasar yang sangat emosional dan volatil. Hal ini sejalan dengan temuan Karagiannopoulou, Ragazou, Passas, dkk. [34] dan Moro-Visconti dan Cesaretti [35] yang menekankan peran sentimen dalam memperkuat dampak kejadian eksternal terhadap pasar kripto.

Sebaliknya, pada periode ketika pasar menunjukkan optimisme tinggi, seperti awal tahun 2021 dan sepanjang tahun 2024, FGI bertransisi ke warna-warna yang lebih terang seperti kuning dan hijau, mengindikasikan dominasi sentimen positif. Khususnya, lonjakan harga Bitcoin pada awal 2021 bertepatan dengan peningkatan partisipasi institusional, sedangkan tren pemulihan tahun 2024 dipicu oleh persetujuan ETF Bitcoin spot di Amerika Serikat. Pada kedua

periode tersebut, dominasi zona *Greed* dan *Extreme Greed* dapat diamati secara visual. Fenomena ini mendukung hipotesis adanya efek *FOMO* yang mendorong investor masuk ke pasar karena takut tertinggal dari tren kenaikan [36].

Hasil eksplorasi menunjukkan pola temporal antara sentimen pasar dan harga Bitcoin, di mana fase *Extreme Fear* kerap bertepatan dengan penurunan harga, sedangkan sentimen *Greed* cenderung menyertai lonjakan harga. Temuan ini menjadi dasar penambahan fitur korelasi bulanan antara FGI dan komponen harga dalam proses *feature engineering*, guna merepresentasikan dinamika lokal sentimen-harga secara kontekstual dalam model *Multivariate Long Short-Term Memory* (LSTM).

4.2 Preprocessing Data

4.2.1 Integrasi Data

Tahap awal *preprocessing* dilakukan dengan mengintegrasikan data harga Bitcoin dan indeks FGI berdasarkan format tanggal *datetime* sebagai kunci penggabungan. Sebelum proses integrasi, struktur awal masing-masing data ditampilkan pada Tabel 3.1 dan Tabel 3.2. Hasil integrasi menghasilkan data gabungan yang mencakup seluruh fitur harga Bitcoin beserta nilai FGI untuk setiap observasi harian. Proses ini sangat penting karena model LSTM sensitif terhadap urutan dan kontinuitas data deret waktu, sehingga kesalahan dalam integrasi dapat menyebabkan hilangnya informasi temporal atau menimbulkan bias. Struktur akhir dari data yang telah terintegrasi ditampilkan pada Tabel 4.1.

Tabel 4.1 Struktur Data Gabungan Setelah Integrasi

Date	Close	High	Low	Open	Volume	FGI
2018-02-02	8830.75	9142.28	7796.49	9142.28	1.272690e+10	15
2018-02-03	9174.91	9430.75	8251.63	8852.12	7.263790e+09	40
2018-02-04	8277.01	9334.87	8031.22	9175.70	7.073550e+09	24
2018-02-05	6955.27	8364.84	6756.68	8270.54	9.285290e+09	11
2018-02-06	7754.00	7850.70	6048.26	7051.75	1.399980e+10	8
...

Date	Close	High	Low	Open	Volume	FGI
2025-05-26	109440.37	110376.88	108735.64	109023.78	4.595046e+10	73
2025-05-27	108994.64	110744.21	107609.55	109440.41	5.745018e+10	74
2025-05-28	107802.33	109298.29	106812.93	108992.17	4.915538e+10	71
2025-05-29	105641.76	108910.05	105374.40	107795.57	5.602275e+10	74
2025-05-30	103998.57	106308.95	103685.79	105646.21	5.765529e+10	60

4.2.2 Analisis Korelasi

Sebelum FGI dimasukkan ke dalam model, perlu dilakukan analisis keterkaitan dengan fitur internal Bitcoin. Hal ini bertujuan untuk memastikan bahwa penyertaan variabel eksternal ini secara statistik relevan dan berpotensi meningkatkan kinerja prediktif. Analisis korelasi dilakukan dalam dua pendekatan, yaitu korelasi global dan korelasi per bulan, sebagai dasar dari strategi *feature engineering* [11], [10].

4.2.2.1 Korelasi Global

Analisis korelasi global dilakukan menggunakan pendekatan Pearson untuk mengukur hubungan *linear* antara indeks *Crypto Fear and Greed Index* (FGI) dan fitur internal harga Bitcoin, seperti ditunjukkan pada Tabel 4.2. Nilai koefisien korelasi (r) antara FGI dan empat fitur harga utama (*close*, *high*, *low*, dan *open*) berada pada kisaran 0,38, sementara korelasi terhadap *volume* tercatat sebesar 0,31. Nilai-nilai tersebut merepresentasikan kekuatan hubungan yang lemah hingga sedang dalam konteks statistik inferensial. Dalam prosedur pengujian Pearson, nilai r yang diperoleh digunakan untuk menghitung statistik uji t , yang kemudian dibandingkan dengan distribusi t -Student untuk menghasilkan nilai p -value. Seluruh pasangan variabel menunjukkan p -value yang sangat kecil, yaitu dalam rentang 10^{-61} hingga 10^{-93} , jauh di bawah ambang signifikansi konvensional ($\alpha = 0,05$). Hal ini mengindikasikan bahwa hubungan yang terdeteksi tidak terjadi secara kebetulan, melainkan signifikan secara statistik. Dengan demikian, dapat disimpulkan bahwa terdapat keterkaitan yang bermakna antara FGI dan fitur-fitur harga Bitcoin, sehingga mendukung validitas FGI


sebagai variabel tambahan yang relevan dalam pemodelan prediktif berbasis *Multivariate* LSTM.

Tabel 4.2 Nilai Korelasi dan *P-value* antara FGI dan Fitur Harga Bitcoin

Pasangan Variabel	Korelasi (r)	<i>P-value</i>	Signifikan
FGI terhadap Close	0,38	$2,06 \times 10^{-93}$	Ya
FGI terhadap High	0,38	$4,94 \times 10^{-93}$	Ya
FGI terhadap Low	0,38	$1,61 \times 10^{-93}$	Ya
FGI terhadap Open	0,38	$4,57 \times 10^{-93}$	Ya
FGI terhadap Volume	0,31	$4,14 \times 10^{-61}$	Ya


4.2.2.2 Korelasi Per Bulan

Untuk menangkap dinamika temporal secara lebih detail, dilakukan analisis korelasi antara FGI dan masing-masing fitur harga Bitcoin secara terpisah untuk setiap bulan. Hasil yang ditampilkan pada Gambar 4.3 menunjukkan bahwa korelasi bulanan FGI terhadap fitur *close*, *high*, *low*, dan *open* bersifat fluktuatif dan tidak konsisten antar periode. Nilai korelasi berkisar dari sangat rendah hingga mendekati 1, dengan kecenderungan lebih kuat pada bulan-bulan tertentu seperti Maret hingga Oktober dalam beberapa tahun. Oleh karena itu, fitur korelasi per bulan ini berpotensi meningkatkan ketepatan model prediktif dengan memberikan informasi tambahan mengenai kekuatan hubungan sentimen dan harga pada masing-masing jendela waktu.



Gambar 4.3 Korelasi Per Bulan FGI terhadap Fitur Bitcoin

Sementara itu, Gambar 4.4 menunjukkan bahwa korelasi per bulan antara FGI dan *Volume* cenderung lemah, tidak stabil, dan sering kali negatif. Tidak seperti fitur harga yang memiliki struktur korelasi musiman, hubungan antara sentimen pasar dan volume transaksi lebih acak dan tidak menunjukkan pola yang konsisten secara temporal. Hal ini mengindikasikan bahwa volume transaksi Bitcoin mungkin dipengaruhi oleh faktor-faktor eksternal yang tidak sepenuhnya terekspresikan dalam indeks FGI. Meski demikian, fitur *Volume* tetap dipertahankan sebagai salah satu *input* karena volume merupakan indikator penting dari kekuatan pasar dan likuiditas, serta berperan sebagai sinyal pendukung dalam interpretasi teknikal.



Gambar 4.4 Korelasi Per Bulan FGI terhadap *Volume*

4.2.3 Feature Engineering

Tabel 4.3 menampilkan lima fitur korelasi bulanan antara FGI dan masing-masing komponen harga Bitcoin yang dihasilkan melalui metode Pearson. Nilai korelasi tersebut ditetapkan sebagai fitur statis bulanan dan disematkan ke setiap baris data harian sesuai bulan terkait. Strategi ini dirujuk dari temuan bahwa keterkaitan antara indikator pasar dan harga aset cenderung berubah seiring waktu dan tergantung pada konteks pasar. Sebagaimana ditunjukkan oleh Choi [11], penggunaan korelasi antar saham sebagai *input* dinamis dalam model LSTM dapat meningkatkan kinerja prediksi. Hal serupa juga ditemukan oleh Agrawal dkk. [10], yang menunjukkan bahwa penambahan fitur korelasi antar indikator teknikal memberikan dampak positif terhadap akurasi model. Dengan pendekatan ini, informasi hubungan temporal antara sentimen dan harga berhasil direpresentasikan tanpa menambah kompleksitas dimensi waktu. Seluruh fitur hasil *feature engineering* digunakan dalam Model 2 sebagai bagian dari vektor *input* pada arsitektur *Multivariate Long Short-Term Memory* (LSTM).

Tabel 4.3 Korelasi Per Bulan FGI terhadap Fitur Harga Bitcoin

Bulan	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
2018-02	0.5849	0.6890	0.7372	0.7562	-0.2128

Bulan	<i>corr fgi_open</i>	<i>corr fgi_high</i>	<i>corr fgi_low</i>	<i>corr fgi_close</i>	<i>corr fgi_volume</i>
2018-03	0.8922	0.9047	0.8823	0.8826	0.3771
2018-04	0.8679	0.8266	0.8172	0.7625	0.6941
2018-05	0.9302	0.9316	0.9386	0.9233	0.7348
2018-06	0.7622	0.7408	0.7721	0.7240	0.0271
...
2025-01	0.7609	0.7045	0.6878	0.6444	0.1440
2025-02	0.9647	0.8956	0.8878	0.8402	-0.3445
2025-03	0.2027	-0.0588	0.2815	-0.0592	-0.3561
2025-04	0.9416	0.9137	0.8934	0.8520	-0.3137
2025-05	0.7595	0.7157	0.7298	0.7005	0.4537

Dengan demikian, daftar fitur yang digunakan dalam masing-masing model disajikan pada Tabel 4.4.

Tabel 4.4 Perbandingan Fitur yang Digunakan pada Model 1 dan Model 2

Model 1	Model 2
<i>Open Price</i>	<i>Open Price</i>
<i>High Price</i>	<i>High Price</i>
<i>Low Price</i>	<i>Low Price</i>
<i>Close Price</i>	<i>Close Price</i>
<i>Volume</i>	<i>Volume</i>
	<i>Fear and Greed Index (FGI)</i>
	<i>corr_fgi_open</i>
	<i>corr_fgi_high</i>
	<i>corr_fgi_low</i>
	<i>corr_fgi_close</i>
	<i>corr_fgi_volume</i>

4.2.4 Pembagian dan Normalisasi Data


Setelah proses rekayasa fitur, data dibagi secara berurutan berdasarkan waktu menjadi tiga bagian, yaitu data latih sebesar 70%, data validasi 10%, dan data uji 20%. Pembagian dilakukan tanpa pengacakan

(*shuffling*) untuk menjaga konsistensi pola temporal dan menghindari *data leakage*, sesuai dengan prinsip umum dalam pemodelan deret waktu [37]. Pembagian ini memungkinkan model belajar dari pola historis masa lalu dan dievaluasi terhadap data masa depan secara berurutan, yang merefleksikan kondisi prediksi di dunia nyata. Rincian jumlah baris pada masing-masing bagian ditampilkan pada Tabel 4.5.

Tabel 4.5 Pembagian Dataset Setelah Rekayasa Fitur

Jenis Data	Persentase	Jumlah Baris
Data Latih	70%	1.869
Data Validasi	10%	267
Data Uji	20%	535
Total	100%	2.671

Seluruh fitur numerik kemudian dinormalisasi ke dalam rentang $[0, 1]$ menggunakan metode *Min-Max Scaler* [17], sebagaimana dijelaskan pada Persamaan 2.3. Proses normalisasi didasarkan pada nilai minimum dan maksimum dari data latih untuk menghindari terjadinya *data leakage*, dan transformasi yang sama diterapkan secara konsisten pada data validasi maupun uji. Visualisasi hasil normalisasi untuk fitur *Close* ditunjukkan pada Gambar 4.5. Pada gambar tersebut, garis hitam merepresentasikan nilai harga penutupan yang telah dinormalisasi. Area berwarna biru menggambarkan data latih (70%), yang berakhir pada batas vertikal biru putus-putus. Selanjutnya, area kuning menandai rentang data validasi (10%), dengan batas akhirnya ditunjukkan oleh garis vertikal merah putus-putus. Sementara itu, area merah muda menunjukkan rentang data uji (20%) yang mencakup bagian akhir dari deret waktu. Visualisasi ini menunjukkan bahwa fitur *Close* telah berhasil disesuaikan skalanya di seluruh *subset* data, sehingga memastikan proporsi dan distribusi nilai tetap konsisten sepanjang proses pelatihan hingga evaluasi model.



Gambar 4.5 Hasil Pembagian Data *Close* Setelah Normalisasi

Untuk memberikan gambaran konkret mengenai hasil normalisasi, Tabel 4.6 menyajikan cuplikan data latih setelah transformasi *Min-Max Scaling*. Skala ini ditentukan berdasarkan nilai minimum dan maksimum pada *subset* data latih.

Tabel 4.6 Data Latih Setelah Normalisasi

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.09	0.09	0.07	0.09	0.03	0.11	0.63	0.71	0.78	0.82	0.20
0.09	0.09	0.08	0.09	0.01	0.39	0.63	0.71	0.78	0.82	0.20
0.08	0.09	0.08	0.09	0.01	0.21	0.63	0.71	0.78	0.82	0.20
0.06	0.08	0.06	0.08	0.02	0.07	0.63	0.71	0.78	0.82	0.20
0.07	0.07	0.05	0.06	0.03	0.03	0.63	0.71	0.78	0.82	0.20
...
0.33	0.34	0.33	0.33	0.12	0.50	0.95	0.92	0.95	0.92	0.30
0.34	0.33	0.33	0.33	0.09	0.52	0.95	0.92	0.95	0.92	0.30
0.38	0.37	0.34	0.34	0.14	0.51	0.95	0.92	0.95	0.92	0.30
0.37	0.37	0.37	0.38	0.09	0.66	0.95	0.92	0.95	0.92	0.30
0.39	0.38	0.38	0.37	0.10	0.64	0.95	0.92	0.95	0.92	0.30

Selanjutnya, Tabel 4.7 menampilkan cuplikan data validasi yang telah dinormalisasi menggunakan skala yang sama dengan data latih. Konsistensi transformasi ini bertujuan untuk menjaga integritas distribusi data antar *subset*.

Tabel 4.7 Data Validasi Setelah Normalisasi

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.38	0.39	0.38	0.39	0.12	0.68	0.95	0.92	0.95	0.92	0.30
0.39	0.38	0.38	0.38	0.10	0.70	0.95	0.92	0.95	0.92	0.30
0.37	0.39	0.37	0.39	0.09	0.63	0.95	0.92	0.95	0.92	0.30

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.39	0.39	0.38	0.37	0.06	0.58	0.95	0.92	0.95	0.92	0.30
0.38	0.38	0.38	0.39	0.07	0.62	0.95	0.92	0.95	0.92	0.30
...
0.62	0.62	0.63	0.63	0.07	0.74	0.17	0.12	0.21	0.19	0.51
0.64	0.63	0.63	0.62	0.06	0.74	0.17	0.12	0.21	0.19	0.51
0.63	0.63	0.64	0.64	0.04	0.76	0.17	0.12	0.21	0.19	0.51
0.63	0.62	0.64	0.63	0.03	0.77	0.17	0.12	0.21	0.19	0.51
0.59	0.62	0.59	0.63	0.11	0.77	0.17	0.12	0.21	0.19	0.51

Terakhir, Tabel 4.8 menyajikan cuplikan data uji yang telah melalui proses normalisasi berdasarkan rentang nilai pada data latih. Beberapa fitur seperti *close*, *high*, *low*, dan *open* menunjukkan nilai di atas 1, yang menandakan bahwa data uji mengandung nilai aktual yang melebihi maksimum pada data pelatihan. Hal ini umum terjadi dalam konteks deret waktu, terutama ketika terjadi tren kenaikan harga setelah periode pelatihan [37].

Tabel 4.8 Data Uji Setelah Normalisasi

<i>Close</i>	<i>High</i>	<i>Low</i>	<i>Open</i>	<i>Volume</i>	<i>FGI</i>	<i>corr</i> <i>fgi_open</i>	<i>corr</i> <i>fgi_high</i>	<i>corr</i> <i>fgi_low</i>	<i>corr</i> <i>fgi_close</i>	<i>corr</i> <i>fgi_volume</i>
0.59	0.59	0.59	0.59	0.06	0.69	0.17	0.12	0.21	0.19	0.51
0.62	0.61	0.59	0.59	0.07	0.67	0.17	0.12	0.21	0.19	0.51
0.62	0.61	0.61	0.62	0.07	0.74	0.17	0.12	0.21	0.19	0.51
0.60	0.61	0.61	0.62	0.05	0.72	0.17	0.12	0.21	0.19	0.51
0.61	0.60	0.61	0.60	0.03	0.69	0.17	0.12	0.21	0.19	0.51
...
1.65	1.63	1.67	1.64	0.12	0.76	0.79	0.74	0.77	0.76	0.71
1.64	1.64	1.65	1.65	0.16	0.77	0.79	0.74	0.77	0.76	0.71
1.63	1.62	1.64	1.64	0.13	0.73	0.79	0.74	0.77	0.76	0.71
1.59	1.61	1.62	1.63	0.15	0.77	0.79	0.74	0.77	0.76	0.71
1.57	1.57	1.59	1.59	0.16	0.61	0.79	0.74	0.77	0.76	0.71

4.3 Konfigurasi *Hyperparameter*

Proses tuning dilakukan untuk memperoleh konfigurasi *hyperparameter* yang menghasilkan kinerja prediksi terbaik. Ruang pencarian terdiri atas 5.832 kombinasi untuk masing-masing model.

Mengingat besarnya ruang eksplorasi, algoritma *Hyperband* digunakan untuk menyeleksi kandidat terbaik secara efisien melalui mekanisme *successive halving*. Dari total ruang tersebut, sebanyak 763 konfigurasi dievaluasi untuk tiap model. Selanjutnya, 50 kombinasi terbaik dengan nilai *validation loss* terendah diseleksi dan dianalisis lebih lanjut pada bagian berikut.

4.3.1 Konfigurasi dan Hasil Tuning Model 1

Model 1 dibangun dengan hanya menggunakan fitur historis internal Bitcoin, tanpa informasi eksternal seperti *Fear and Greed Index* (FGI). Konfigurasi terbaik terdiri atas satu lapisan *LSTM* dengan 128 unit, *dropout* sebesar 0,1, regularisasi kernel L2 sebesar 0,0001, *batch size* 32, dan *learning rate* 0,01. Panjang urutan waktu (*sequence length*) optimal adalah 14 hari. Kombinasi ini menghasilkan nilai MSE validasi minimum sebesar 0,000101. Detail lengkap konfigurasi terbaik ini dapat dilihat pada Tabel 4.9, yang menyajikan seluruh *hyperparameter* dan nilai terbaik yang digunakan dalam pelatihan akhir.

Tabel 4.9 Parameter Terbaik untuk Model 1

<i>Hyperparameter</i>	Nilai Terbaik
<i>Sequence Length</i>	14
Jumlah Lapisan <i>LSTM</i>	1
Jumlah Unit	128
<i>Dropout</i>	0.1
Regulasi Kernel (L2)	0.0001
<i>Batch Size</i>	32
<i>Optimizer</i>	Adam
<i>Learning Rate</i>	0.01

Tabel 4.10 menyajikan sepuluh kombinasi *hyperparameter* dengan nilai MSE validasi terendah dan tertinggi dari seluruh proses tuning pada Model 1. Hasil menunjukkan bahwa konfigurasi terbaik umumnya menggunakan arsitektur sederhana (satu lapisan *LSTM*),

jumlah unit antara 64 hingga 128, *dropout* rendah, serta *optimizer* Adam yang lebih stabil untuk data deret waktu. Sebaliknya, konfigurasi dengan performa buruk cenderung melibatkan arsitektur kompleks (dua atau tiga lapisan), *learning rate* tinggi (0,1), dan *optimizer* RMSprop yang menunjukkan instabilitas dalam konteks ini. Dari seluruh hasil, ID 462 dipilih sebagai konfigurasi terbaik karena memiliki nilai MSE validasi paling rendah dan struktur yang seimbang antara kompleksitas dan stabilitas. Meskipun ID 716 mencatatkan nilai MSE identik, parameter seperti *batch size* yang lebih besar dan *dropout* yang lebih tinggi pada ID 716 menunjukkan fluktuasi pelatihan yang lebih besar, sehingga ID 462 lebih layak dijadikan dasar arsitektur akhir Model 1.

Tabel 4.10 Konfigurasi *Hyperparameter Tuning* Model 1

ID	MSE	Seq L	LSTM	Unit			Dropout			L2	Opti mizer	Learning Rate	Batch Size
				1	2	3	1	2	3				
462	0.000101	14	1	128	96	96	0.10	0.10	0.01	0.0001	adam	0.01	32
716	0.000101	21	1	64	128	96	0.20	0.20	0.20	0.0001	adam	0.01	64
208	0.000102	7	1	64	128	128	0.20	0.01	0.20	0.0001	adam	0.01	64
654	0.000102	21	1	64	64	128	0.01	0.20	0.10	0.0001	adam	0.01	64
650	0.000102	21	1	64	64	128	0.01	0.20	0.10	0.0001	adam	0.01	64
463	0.000103	14	1	64	64	96	0.10	0.01	0.20	0.0010	adam	0.01	32
742	0.000103	21	1	128	128	64	0.10	0.10	0.01	0.0001	adam	0.01	32
400	0.000104	14	1	64	64	128	0.10	0.10	0.01	0.0001	adam	0.0010	32
717	0.000104	21	1	96	64	128	0.20	0.01	0.10	0.0001	adam	0.01	128
753	0.000106	21	1	96	128	128	0.10	0.01	0.01	0.0010	adam	0.01	32
...
263	1.439833	14	3	128	64	96	0.10	0.10	0.01	0.0001	rmsprop	0.10	128
580	2.015894	21	3	128	96	96	0.01	0.20	0.20	0.0001	rmsprop	0.10	64
86	2.049962	7	1	96	64	64	0.01	0.10	0.20	0.01	rmsprop	0.10	128
274	2.498899	14	2	64	64	96	0.01	0.01	0.10	0.01	rmsprop	0.10	64
600	2.693460	21	1	128	96	96	0.20	0.20	0.10	0.01	rmsprop	0.10	128
88	3.602457	7	2	96	96	64	0.10	0.01	0.10	0.0010	rmsprop	0.10	32
510	4.524909	21	2	64	96	NaN	0.20	0.01	NaN	0.0001	rmsprop	0.10	32
561	5.485112	21	1	128	64	96	0.20	0.20	0.10	0.0001	rmsprop	0.10	32
330	9.198813	14	2	64	128	128	0.10	0.10	0.20	0.0010	rmsprop	0.10	128
63	10.657529	7	3	64	96	128	0.01	0.01	0.20	0.01	rmsprop	0.10	32

4.3.2 Konfigurasi dan Hasil Tuning Model 2

Model 2 dilatih dengan memasukkan fitur tambahan berupa *Fear and Greed Index* (FGI) dan korelasi bulanan FGI terhadap fitur-fitur harga dan volume. Hasil tuning menunjukkan konfigurasi terbaik terdiri dari satu lapisan *LSTM* dengan 128 unit, *dropout* 0,01, regularisasi kernel L2 sebesar 0,0001, *batch size* 64, dan *learning rate* 0,01, dengan panjang urutan waktu optimal selama 7 hari. Kombinasi ini menghasilkan nilai MSE validasi minimum sebesar 0,000102. Detail konfigurasi terbaik untuk Model 2 disajikan pada Tabel 4.11, yang memuat seluruh parameter beserta nilai optimal hasil tuning.

Tabel 4.11 Parameter Terbaik untuk Model 2

<i>Hyperparameter</i>	Nilai Terbaik
<i>Sequence Length</i>	7
Jumlah Lapisan <i>LSTM</i>	1
Jumlah Unit	128
<i>Dropout</i>	0.01
Regulasi Kernel (L2)	0.0001
<i>Batch Size</i>	64
<i>Optimizer</i>	Adam
<i>Learning Rate</i>	0.01

Tabel 4.12 merangkum sepuluh kombinasi *hyperparameter* terbaik dan terburuk dari 762 konfigurasi yang diuji untuk Model 2. Pola konfigurasi optimal cenderung menyerupai Model 1, terutama pada pemilihan *optimizer* Adam dan *learning rate* 0,01. Namun, adanya fitur eksternal tampaknya mempercepat pembelajaran pola pasar, sebagaimana ditunjukkan oleh panjang urutan waktu optimal yang lebih pendek (7 hari). Sebaliknya, konfigurasi dengan performa buruk umumnya memiliki arsitektur kompleks dan *learning rate* tinggi, serta menggunakan *optimizer* RMSprop, yang juga menghasilkan MSE tinggi pada Model 1. Tabel ini menegaskan bahwa penambahan informasi kontekstual (FGI dan korelasi) dapat meningkatkan efisiensi pembelajaran tanpa menambah kompleksitas arsitektur secara

signifikan.

Tabel 4.12 Konfigurasi *Hyperparameter Tuning* Model 2

ID	MSE	Seq L	LSTM	Unit			Dropout			L2	Opti mizer	Learning Rate	Batch Size
				1	2	3	1	2	3				
146	0.000102	7	1	128	96	64	0.01	0.20	0.20	0.0001	adam	0.01	64
250	0.000104	7	1	64	96	96	0.01	0.10	0.01	0.0001	adam	0.01	64
463	0.000104	14	1	128	96	64	0.10	0.10	0.10	0.0010	adam	0.01	32
401	0.000105	14	1	128	64	64	0.20	0.01	0.01	0.0001	adam	0.01	32
502	0.000105	14	1	128	96	64	0.10	0.10	0.01	0.0001	adam	0.01	32
400	0.000106	14	1	128	96	128	0.10	0.10	0.20	0.0001	adam	0.01	32
654	0.000107	21	1	96	128	128	0.20	0.10	0.20	0.0001	adam	0.01	64
147	0.000107	7	1	128	128	96	0.01	0.01	0.10	0.0001	adam	0.0010	64
716	0.000112	21	1	128	128	128	0.10	0.10	0.01	0.0001	adam	0.01	32
209	0.000113	7	1	64	64	96	0.20	0.20	0.01	0.0001	adam	0.0010	32
...
329	1.467640	14	1	96	64	128	0.01	0.01	0.10	0.0001	rmsprop	0.10	64
597	1.574949	21	1	96	128	96	0.10	0.01	0.20	0.01	rmsprop	0.10	64
267	1.795949	14	1	128	64	64	0.10	0.20	0.20	0.01	adam	0.10	128
668	1.970428	21	3	96	64	128	0.01	0.20	0.10	0.01	rmsprop	0.10	64
277	2.083627	14	2	64	96	96	0.20	0.20	0.10	0.0010	rmsprop	0.10	32
61	2.336715	7	3	96	128	96	0.20	0.01	0.01	0.0001	rmsprop	0.10	64
479	2.402305	14	3	128	64	128	0.10	0.01	0.20	0.01	rmsprop	0.10	32
336	2.617528	14	2	96	96	128	0.20	0.10	0.20	0.01	rmsprop	0.10	32
266	4.868916	14	3	64	128	128	0.20	0.20	0.20	0.01	rmsprop	0.10	64
54	10.804993	7	2	64	128	64	0.10	0.01	0.01	0.0010	rmsprop	0.10	32

4.3.3 Analisis Distribusi Konfigurasi Terbaik

Evaluasi dilakukan terhadap distribusi *hyperparameter* dari 50 kombinasi terbaik berdasarkan nilai MSE validasi, yang diambil dari total 763 konfigurasi yang diuji untuk masing-masing model. Hasil distribusi ini ditampilkan pada Tabel 4.13 dan memberikan gambaran umum mengenai kecenderungan pemilihan arsitektur selama proses tuning. Hasilnya menunjukkan kecenderungan arsitektur yang serupa pada kedua model, dominasi satu lapisan *LSTM* dan *optimizer* Adam. Namun, Model 2 menunjukkan proporsi RMSprop lebih tinggi (28%) dibanding Model 1 (8%) serta preferensi unit lebih besar (128 unit pada 48% kombinasi terbaik). Dari sisi *sequence length*, Model 1 lebih condong ke 21 hari (50%), sementara Model 2 ke 7 hari (42%),

mencerminkan perbedaan preferensi temporal yang konsisten. Temuan ini mendukung bahwa arsitektur sederhana namun stabil efektif untuk mempelajari dinamika harga Bitcoin, khususnya saat fitur sentimen eksternal disertakan.


Tabel 4.13 Distribusi 50 Kombinasi *Hyperparameter* Terbaik untuk Kedua Model

<i>Hyperparameter</i>	Model 1	Model 2
<i>Optimizer</i>		
Adam	92.0%	72.0%
RMSprop	8.0%	28.0%
Jumlah Lapisan LSTM		
1 <i>Layer</i>	94.0%	98.0%
2 <i>Layer</i>	6.0%	2.0%
Jumlah <i>Unit</i> LSTM		
64 <i>Unit</i>	56.0%	26.0%
96 <i>Unit</i>	20.0%	26.0%
128 <i>Unit</i>	24.0%	48.0%
<i>Batch Size</i>		
32	46.0%	50.0%
64	44.0%	44.0%
128	10.0%	6.0%
<i>Dropout</i>		
0.01	38.0%	36.0%
0.10	36.0%	32.0%
0.20	26.0%	32.0%
Regulasi Kernel (L2)		
0.0001	62.0%	78.0%
0.0010	38.0%	22.0%
<i>Sequence Length</i>		
7 Hari	16.0%	42.0%
14 Hari	34.0%	30.0%
21 Hari	50.0%	28.0%

4.4 Struktur *Input*


Proses *hyperparameter tuning* menghasilkan struktur *input* yang berbeda untuk masing-masing model, sesuai konfigurasi optimal yang

diperoleh. Model 1 membentuk tensor berdimensi (32, 14, 5), yang terdiri dari 32 sampel per *batch*, masing-masing mencakup urutan waktu selama 14 hari dengan lima fitur internal Bitcoin. Struktur tensor tiga dimensi tersebut ditampilkan pada Gambar 4.6, yang menggambarkan bagaimana data historis dikelompokkan ke dalam *batch* untuk proses pembelajaran.



Gambar 4.6 Struktur Tensor Optimal Model 1 (32, 14, 5)


Gambar 4.7 berikut menjelaskan mekanisme pembentukan pasangan *input-output* Model 1 dengan pendekatan *sliding window*. Dalam proses ini, 14 langkah waktu digunakan untuk memprediksi nilai pada hari ke-15, kemudian jendela digeser satu hari ke depan untuk membentuk pasangan baru.



Gambar 4.7 Mekanisme *Sliding Window* Model 1 dengan *Sequence Length* 14


Model 2 menghasilkan struktur *input* dengan dimensi tensor (64, 7, 11), yang mencakup 64 sampel per *batch*, masing-masing berisi 7 langkah waktu dan 11 fitur. Penambahan enam fitur eksternal—terdiri dari nilai FGI dan lima korelasi bulanannya—meningkatkan kedalaman representasi input. Gambar 4.8 menunjukkan struktur tensor tersebut, di mana setiap baris representasi

mencerminkan urutan data yang kaya secara fitur namun lebih singkat secara temporal.



Gambar 4.8 Struktur Tensor Optimal Model 2 (64, 7, 11)

Adapun Gambar 4.9 menampilkan proses *sliding window* pada Model 2. Tujuh hari berturut-turut digunakan sebagai *input* untuk memprediksi nilai pada hari ke-8, dengan jendela yang digeser setiap hari.



Gambar 4.9 Mekanisme *Sliding Window* Model 2 dengan *Sequence Length* 7

4.5 Pelatihan Model

Pelatihan dilakukan untuk meminimalkan kesalahan prediksi harga penutupan Bitcoin melalui proses iteratif yang mencakup perhitungan *loss*, pembaruan bobot menggunakan algoritma *optimizer*, dan evaluasi berulang selama sejumlah *epoch*. Konfigurasi *hyperparameter* optimal diperoleh terlebih dahulu melalui algoritma *Hyperband*, yang mengandalkan alokasi sumber daya adaptif tanpa menyimpan bobot pelatihan. Oleh karena itu, setelah konfigurasi terbaik diidentifikasi, model dilatih ulang dari awal menggunakan seluruh data latih. Kedua model mengadopsi arsitektur identik, terdiri atas satu lapisan *LSTM* berisi 128 unit, satu *Dropout layer*, dan satu lapisan *Dense* untuk

regresi. Tabel 4.14 menampilkan ringkasan arsitektur dan jumlah parameter. Perbedaan utama terletak pada dimensi input, dimana Model 1 menerima 5 fitur, sedangkan Model 2 menggunakan 11 fitur. Hal ini menyebabkan jumlah parameter *LSTM* bertambah dari 68 608 menjadi 71 680. Secara keseluruhan, Model 2 memiliki total parameter latih sebesar 71 809, sedikit lebih banyak dibanding Model 1 yang berjumlah 68 737. Kompleksitas input Model 2 juga tercermin dari parameter yang dikelola oleh *optimizer*, yaitu 143 620 dibandingkan 137 476 pada Model 1.

Tabel 4.14 Ringkasan Arsitektur dan Jumlah Parameter Model

<i>Layer (Type)</i>	<i>Output Shape</i>	<i>Param #</i>
<i>Model 1</i>		
LSTM	(None, 128)	68 608
Dropout	(None, 128)	0
Dense	(None, 1)	129
Total <i>params</i>		68 737
Trainable <i>params</i>		68 737
Non-trainable <i>params</i>		0
Optimizer <i>params</i>		137 476
<i>Model 2</i>		
LSTM	(None, 128)	71 680
Dropout	(None, 128)	0
Dense	(None, 1)	129
Total <i>params</i>		71 809
Trainable <i>params</i>		71 809
Non-trainable <i>params</i>		0
Optimizer <i>params</i>		143 620

4.5.1 Evaluasi Kurva *Loss*


Kurva *loss* pada Gambar 4.10 menunjukkan perubahan nilai MSE selama proses pelatihan sebagai indikator konvergensi dan kemampuan generalisasi model. *Training loss* (garis biru) dihitung sebagai rata-rata kesalahan per *batch* dalam satu *epoch*, sedangkan *validation loss* (garis oranye) dihitung satu kali di akhir *epoch* pada model yang telah

diperbarui, sehingga sering kali berada di bawah *training loss* pada fase awal. Dari nilai awal sebesar 0,0392, *training loss* menurun drastis selama lima *epoch* pertama, mengindikasikan bahwa model dengan cepat mengenali pola dasar dalam data. Setelah melewati *epoch* ke-20, kedua kurva bergerak stabil dan saling mendekat, mencerminkan kemampuan generalisasi yang baik dan tidak terjadi *overfitting*. Nilai *validation loss* terendah tercapai pada *epoch* ke-82 sebesar 1.96×10^{-4} , dengan sedikit fluktuasi pada *epoch* ke-84 yang masih tergolong wajar dalam proses pelatihan.



Gambar 4.10 Kurva *Loss* Model 1.

Sementara itu, Gambar 4.11 memperlihatkan kurva *loss* Model 2 selama pelatihan. Nilai awal *training loss* sebesar 0,0986 lebih tinggi dibandingkan Model 1, mencerminkan kompleksitas *input* akibat penambahan fitur eksternal. Meskipun demikian, penurunan *loss* terjadi sangat cepat sejak *epoch* pertama dan segera mencapai nilai mendekati nol, menunjukkan adaptasi model yang efisien terhadap pola multivariabel. Sepanjang 150 *epoch*, *validation loss* (garis oranye) menurun secara konsisten tanpa fluktuasi berarti, dengan nilai terendah 1.02×10^{-4} pada *epoch* ke-123. Stabilitas ini mengindikasikan bahwa keberadaan fitur tambahan seperti *Fear* and *Greed Index* dan korelasinya membantu menyampaikan sinyal yang lebih informatif, sehingga proses pembelajaran menjadi lebih cepat, stabil, dan tidak bergantung pada konteks historis yang panjang.




Gambar 4.11 Kurva *Loss* Model 2.

4.5.2 Analisis Konvergensi Bobot Jaringan


Konvergensi bobot terjadi ketika nilai bobot dalam lapisan *LSTM* mencapai kestabilan seiring bertambahnya jumlah *epoch*, menandakan bahwa model telah mengenali pola yang konsisten dari data. Untuk memonitor dinamika ini, digunakan statistik deskriptif berupa nilai rata-rata dan standar deviasi bobot. Berbeda dengan pandangan sederhana, dalam optimisasi stokastik modern seperti Adam, konvergensi yang stabil tidak selalu menandakan bahwa proses berada di zona curam. Sebaliknya, menurut Kingma dan Ba [21], ketika proses optimisasi mendekati titik optimum, *signal-to-noise ratio* (SNR) pada gradien cenderung menurun, sehingga pembaruan bobot menjadi lebih kecil secara otomatis sebagai bentuk *automatic annealing*. Hal ini sejalan dengan ulasan oleh Ruder [38], yang menyatakan bahwa *optimizer* adaptif seperti Adam dirancang untuk menavigasi *loss landscape* yang kompleks dan mencapai konvergensi di area yang lebih landai.

Pada Model 1, visualisasi Gambar 4.12 memperlihatkan dinamika bobot yang masih relatif fluktuatif. Gambar 4.12a menampilkan kurva berwarna biru yang menunjukkan rata-rata bobot kernel *LSTM*. Kurva ini naik tajam dari nilai awal sekitar $-0,024$ menuju nol dalam 20 *epoch* pertama, yang dapat diartikan sebagai fase adaptasi cepat awal

(ditandai oleh area abu-abu). Namun, setelah fase ini, fluktuasi mulai muncul secara tidak merata, khususnya setelah *epoch* ke-100. Gambar 4.12b mendukung temuan ini, di mana kurva merah yang menggambarkan standar deviasi bobot tidak sepenuhnya stabil dan menunjukkan getaran kecil di sepanjang pelatihan. Kondisi ini mencerminkan bahwa Adam bekerja dalam lingkungan yang cukup bising, tipikal data keuangan yang penuh noise. Meski demikian, pola penurunan yang tetap konsisten menunjukkan bahwa model masih menuju arah konvergensi.



(a) Rata-rata Bobot

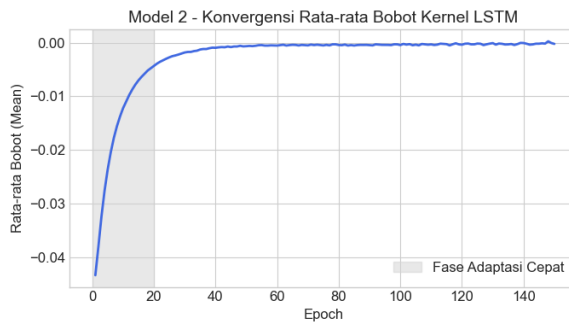


(b) Standar Deviasi


Gambar 4.12 Konvergensi Bobot Jaringan Model 1

Sebaliknya, Model 2 pada Gambar 4.13 menunjukkan pola konvergensi yang jauh lebih stabil dan efisien. Gambar 4.13a memperlihatkan kurva biru yang naik tajam dari $-0,042$ hingga mendekati nol dalam 20 *epoch* pertama, yang juga ditandai sebagai fase adaptasi cepat (area berwarna abu-abu). Setelah itu, rata-rata bobot tetap mendekati nol tanpa fluktuasi berarti sepanjang sisa

pelatihan. Sementara itu, Gambar 4.13b menampilkan kurva merah yang menurun halus dari nilai awal 0,069 ke sekitar 0,011, dengan bentuk kurva yang bersih dan konsisten tanpa guncangan. Pola ini mengindikasikan bahwa penambahan variabel *Fear & Greed Index* (FGI) memberikan sinyal gradien yang lebih informatif dan tidak terlalu bising kepada model. Dengan sinyal yang lebih bersih, mekanisme estimasi momen adaptif dalam Adam dapat bekerja lebih efektif, menghasilkan proses pelatihan yang lebih tenang dan konvergensi yang lebih cepat menuju titik minimum[21]. Kestabilan ini juga tercermin pada nilai *loss* validasi yang cenderung datar, menegaskan bahwa penambahan FGI tidak hanya meningkatkan akurasi prediksi tetapi juga efisiensi proses pembelajaran.



(a) Rata-rata Bobot



(b) Standar Deviasi

Gambar 4.13 Konvergensi Bobot Jaringan Model 2

4.6 Evaluasi Hasil Prediksi

4.6.1 Analisis Hasil Evaluasi dengan MAPE

Tahap evaluasi bertujuan untuk mengukur kemampuan generalisasi model dalam memprediksi harga penutupan Bitcoin berdasarkan data uji yang tidak digunakan selama proses pelatihan. Evaluasi dilakukan menggunakan metrik *Mean Absolute Percentage Error* (MAPE), yang menghitung rata-rata kesalahan absolut dalam bentuk persentase terhadap nilai aktual. MAPE merupakan salah satu metrik yang paling banyak digunakan dalam prediksi pasar keuangan karena bersifat skala-independen dan memiliki interpretasi yang intuitif [15], [39]. Dalam konteks aset kripto yang volatil, model dengan MAPE di bawah 10% dianggap cukup andal [40]. Tabel 4.15 menyajikan nilai MAPE dari dua model yang diuji dalam penelitian ini.

Tabel 4.15 Perbandingan Kinerja Final Model Berdasarkan Nilai MAPE

Model	MAPE (%)
Model 1	6.02
Model 2	2.33


4.6.2 Analisis Hasil Prediksi

Gambar 4.14 menampilkan hasil prediksi akhir menggunakan Model 2, yaitu model *Multivariate LSTM* yang mengintegrasikan indikator sentimen *Fear and Greed Index* (FGI) serta lima fitur korelasi bulanan terhadap fitur internal Bitcoin. Dalam visualisasi ini, garis hitam menunjukkan harga aktual, sedangkan garis biru merepresentasikan prediksi model. Area abu-abu mengilustrasikan selisih antara prediksi dan data aktual sebagai indikator galat.

Model ini berhasil mencapai tingkat akurasi tinggi dengan nilai MAPE sebesar 2,33%, menandakan keunggulan signifikan dibanding baseline. Secara visual, prediksi mengikuti arah tren harga dengan lebih presisi, termasuk dalam situasi perubahan tren yang ekstrem. Tingkat keterlambatan (lag) juga tampak minimal. Temuan ini memperkuat

hasil studi sebelumnya oleh Mahdi *et al.* [15], Jiang *et al.* [41], dan Agrawal *et al.* [40], yang menegaskan bahwa integrasi indikator sentimen ke dalam model prediktif mampu meningkatkan akurasi dan responsivitas terhadap dinamika pasar kripto.

Adopsi fitur korelasi bulanan dalam penelitian ini juga berperan penting dalam menangkap dinamika relasi jangka pendek antara sentimen dan harga, memungkinkan model menyesuaikan bobot input secara kontekstual. Secara keseluruhan, hasil ini menunjukkan bahwa integrasi FGI tidak hanya meningkatkan akurasi kuantitatif, tetapi juga memperkuat stabilitas dan adaptabilitas model dalam menghadapi volatilitas pasar.



Gambar 4.14 Prediksi Model 2 terhadap Data Uji (dengan FGI dan korelasi bulanan)

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan terhadap perancangan dan implementasi model prediksi harga Bitcoin menggunakan *Multivariate Long Short-Term Memory* (LSTM) serta integrasi *Crypto Fear and Greed Index* (FGI), maka dapat disimpulkan hal-hal sebagai berikut:

1. Penelitian ini berhasil merancang dan mengimplementasikan model prediksi harga Bitcoin berbasis *Multivariate LSTM* dalam dua skenario: Model 1 sebagai *baseline* yang hanya menggunakan lima fitur internal harga Bitcoin, dan Model 2 yang mengintegrasikan data FGI serta lima fitur korelasi bulanan antara FGI dan komponen harga (*open, high, low, close, volume*). Proses pelatihan dan *hyperparameter tuning* dilakukan menggunakan metode *Hyperband* dengan metrik *Mean Squared Error* (MSE) pada data validasi, serta *early stopping* untuk mencegah *overfitting*.
2. Hasil evaluasi menunjukkan bahwa penyertaan FGI dan fitur korelasi bulanan pada Model 2 secara signifikan meningkatkan akurasi prediksi dibandingkan dengan Model 1. Nilai *Mean Absolute Percentage Error* (MAPE) pada data uji lebih rendah pada Model 2, yang mengindikasikan bahwa integrasi variabel sentimen dan korelasi temporal memberikan kontribusi positif terhadap performa prediktif. Hal ini membuktikan bahwa sentimen pasar yang bersifat dinamis memiliki peran penting dalam memodelkan perilaku harga Bitcoin.

5.2 Saran

Berdasarkan keterbatasan dan hasil yang diperoleh, beberapa saran dapat diberikan untuk pengembangan penelitian lebih lanjut, yaitu:

1. Disarankan untuk mempertimbangkan integrasi sumber sentimen lain yang bersifat *real-time*, seperti data dari media sosial (misalnya Twitter atau Reddit) maupun volume pencarian dari Google Trends, guna memperkaya representasi emosi pasar yang digunakan dalam model.
2. Pengembangan arsitektur model dapat diarahkan pada pendekatan *hybrid* atau *ensemble*, seperti menggabungkan LSTM dengan model *Extreme Gradient Boosting* (XGBoost) atau menggunakan mekanisme *Attention*, agar mampu menangkap pola yang lebih kompleks baik secara temporal maupun spasial.
3. Penelitian selanjutnya disarankan untuk menguji robustitas model terhadap kondisi pasar yang ekstrem, seperti krisis atau lonjakan harga mendadak, untuk memastikan model mampu beradaptasi dalam lingkungan yang sangat volatil.
4. Implementasi model dalam sistem prediksi harga secara *real-time* yang terhubung dengan pembaruan data harian juga dapat menjadi arah pengembangan praktis, sehingga hasil penelitian ini dapat digunakan sebagai alat bantu pengambilan keputusan oleh investor atau analis pasar.

DAFTAR PUSTAKA

- [1] S. Nakamoto, “Bitcoin whitepaper”, *URL: <https://bitcoin.org/bitcoin.pdf>* (: 17.07. 2019), vol. 9, hlmn. 15, 2008.
- [2] M. V. S. Somayajulu, D. M. Ahmed, dan B. Kotaiah, “Bitcoin price prediction using lstm and cnn”, *Available at SSRN 5190840*, 2025.
- [3] Z. Zhao, “Determinants of ethereum return: Insights from bitcoin, investor sentiment, and financial markets”, *Advances in Economics, Management and Political Sciences*, vol. 65, hlmn. 163–174, Des. 2023.
- [4] Huang, Qichuan, “Bitcoin price prediction based on fear greed index”, *SHS Web Conf.*, vol. 181, hlmn. 02 015, 2024. sumber: <https://doi.org/10.1051/shsconf/202418102015>.
- [5] K. Kim, S.-Y. T. Lee, dan S. Assar, “The dynamics of cryptocurrency market behavior: Sentiment analysis using markov chains”, *Industrial Management & Data Systems*, vol. 122, no. 2, hlmn. 365–395, 2022.
- [6] R. Fioretti, *Predicting bitcoin price with gated recurrent units*, 2024.
- [7] H. S. Htay, M. Ghahremani, dan S. Shiaeles, “Enhancing bitcoin price prediction with deep learning: Integrating social media sentiment and historical data”, *Applied Sciences*, vol. 15, no. 3, hlmn. 1554, 2025.
- [8] B. Scanlon, K. Quille, dan R. Jaiswal, “Optimizing bitcoin price prediction: Multivariate lstm triumphs.”, *International Journal of Combinatorial Optimization Problems & Informatics*, vol. 16, no. 1, 2025.
- [9] A. Gautam, S. Santra, P. Sharma, H. Thomas, dan P. Sharma, “Crypto price prediction using lstm+xgboost”, *arXiv preprint arXiv:2506.22055*, 2024. sumber: <https://arxiv.org/abs/2506.22055>.
- [10] R. Agrawal dkk., “Stock prediction based on technical indicators using deep learning model”, *Computers, Materials & Continua*,

- vol. 70, no. 1, hlmn. 287–304, 2022. sumber: <https://www.techscience.com/cmc/v70n1/44330>.
- [11] H. K. Choi, “Stock price correlation coefficient prediction with arima-lstm hybrid model”, *arXiv preprint arXiv:1808.01560*, 2018.
 - [12] S. I. Olotu, “A multivariate lstm-based deep learning model for stock market prediction”, *Applied and Computational Engineering*, vol. 2, hlmn. 965–973, 2023.
 - [13] M. Crosby, P. Pattanayak, S. Verma, V. Kalyanaraman, dkk., “Blockchain technology: Beyond bitcoin”, *Applied innovation*, vol. 2, no. 6-10, hlmn. 71, 2016.
 - [14] B. S. .-. Alternative.me, *Crypto fear & greed index - bitcoin sentiment*, <https://alternative.me/crypto/fear-and-greed-index/>.
 - [15] E. Mahdi, C. Martin-Barreiro, dan X. Cabezas, “A novel hybrid approach using an attention-based transformer+ gru model for predicting cryptocurrency prices”, *Mathematics*, vol. 13, no. 9, hlmn. 1484, 2025.
 - [16] I. Cohen, Y. Huang, J. Chen, dkk., “Pearson correlation coefficient”, *Noise reduction in speech processing*, hlmn. 1–4, 2009.
 - [17] S. Patro dan K. K. Sahu, “Normalization: A preprocessing stage”, *arXiv preprint arXiv:1503.06462*, 2015.
 - [18] I. Goodfellow, Y. Bengio, A. Courville, dan Y. Bengio, *Deep learning*. MIT press Cambridge, 2016, vol. 1.
 - [19] H. O. M. Omar, S. Goyal, dan V. Varadarajan, “Application of sliding window deep learning for intrusion detection in fog computing”, di dalam *2021 Emerging Trends in Industry 4.0 (ETI 4.0)*, IEEE, 2021, hlmn. 1–6.
 - [20] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, dan R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting”, *The journal of machine learning research*, vol. 15, no. 1, hlmn. 1929–1958, 2014.

- [21] D. P. Kingma dan J. Ba, *Adam: A method for stochastic optimization*, 2017. arXiv: 1412.6980 [cs.LG]. sumber: <https://arxiv.org/abs/1412.6980>.
- [22] G. Hinton, N. Srivastava, dan K. Swersky, “Neural networks for machine learning—lecture 6e—rmsprop: Divide the gradient by a running average of its recent magnitude”, URL: <https://www.cs.toronto.edu/tijmen/csc321/slides/lectureslideslec6.pdf>, 2012.
- [23] S. Susilawati dan M. Muhathir, “Analisis pengaruh fungsi aktivasi, learning rate dan momentum dalam menentukan mean square error (mse) pada jaringan saraf restricted boltzmann machines (rbm)”, *Journal of Informatics and Telecommunication Engineering*, vol. 2, no. 2, hlmn. 77–91, 2019.
- [24] L. Prechelt, “Early stopping-but when?”, di dalam *Neural Networks: Tricks of the trade*, Springer, 2002, hlmn. 55–69.
- [25] H. Pratiwi, A. P. Windarto, S. Susliansyah, dkk., “Sigmoid activation function in selecting the best model of artificial neural networks”, di dalam *Journal of Physics: Conference Series*, IOP Publishing, vol. 1471, 2020, hlmn. 012010.
- [26] B. Zamanlooy dan M. Mirhassani, “Efficient vlsi implementation of neural networks with hyperbolic tangent activation function”, *IEEE Transactions on Very Large Scale Integration (VLSI) Systems*, vol. 22, no. 1, hlmn. 39–48, 2013.
- [27] A. Arfan dan E. Lussiana, “Perbandingan algoritma long short-term memory dengan svr pada prediksi harga saham di indonesia”, 2020.
- [28] J. Cahyani, S. Mujahidin, dan T. P. Fiqar, “Implementasi metode long short term memory (lstm) untuk memprediksi harga bahan pokok nasional”, *JUSTIN (Jurnal Sistem dan Teknologi Informasi)*, vol. 11, no. 2, hlmn. 346–357, 2023.
- [29] R. Ghanbari dan K. Borna, “Multivariate time-series prediction using lstm neural networks”, di dalam *2021 26th International Computer Conference, Computer Society of Iran (CSICC)*, IEEE, 2021, hlmn. 1–5.

- [30] A. K. Mandal, R. Sen, S. Goswami, dan B. Chakraborty, “Comparative study of univariate and multivariate long short-term memory for very short-term forecasting of global horizontal irradiance”, *Symmetry*, vol. 13, no. 8, hlmn. 1544, 2021.
- [31] L. Li, K. Jamieson, G. DeSalvo, A. Rostamizadeh, dan A. Talwalkar, “Hyperband: A novel bandit-based approach to hyperparameter optimization”, *Journal of Machine Learning Research*, vol. 18, no. 185, hlmn. 1–52, 2018.
- [32] I. Nabillah dan I. Ranggadara, “Mean absolute percentage error untuk evaluasi hasil prediksi komoditas laut”, *Journal of Information System*, vol. 5, no. 2, hlmn. 250–255, 2020.
- [33] J. Michańkó, P. Sakowski, dan R. Ślepaczuk, “Lstm in algorithmic investment strategies on btc and s&p500 index”, *Sensors*, vol. 22, no. 3, hlmn. 917, 2022.
- [34] S. Karagiannopoulou, K. Ragazou, I. Passas, A. Garefalakis, dan N. Sariannidis, “The impact of the covid-19 pandemic on the volatility of cryptocurrencies”, *International Journal of Financial Studies*, vol. 11, no. 1, hlmn. 50, 2023.
- [35] R. Moro-Visconti dan A. Cesaretti, “The cryptocurrency crash of 2022: Which lessons for the future?”, di dalam *Digital Token Valuation: Cryptocurrencies, NFTs, Decentralized Finance, and Blockchains*, Springer, 2023, hlmn. 395–410.
- [36] H. Gao dan G. Georgopoulos, “Stock price prediction using sentiment and technical analysis”, di dalam *2024 IEEE/WIC International Conference on Web Intelligence and Intelligent Agent Technology (WI-IAT)*, IEEE, 2024, hlmn. 904–911.
- [37] H. Hewamalage, C. Bergmeir, dan K. Bandara, “Recurrent neural networks for time series forecasting: Current status and future directions”, *International Journal of Forecasting*, vol. 37, no. 1, hlmn. 388–427, 2021.
- [38] S. Ruder, *An overview of gradient descent optimization algorithms*, 2017. arXiv: 1609.04747 [cs.LG]. sumber: <https://arxiv.org/abs/1609.04747>.

- [39] P. L. Seabe, C. R. B. Moutsinga, dan E. Pindza, “Sentiment-driven cryptocurrency forecasting: Analyzing lstm, gru, bi-lstm, and temporal attention model (tam)”, *Social Network Analysis and Mining*, vol. 15, hlmn. 52, 2025.
- [40] A. Agrawal, S. Kadam, V. Jha, dan V. Prakash, “Bitcoin price sentiment analysis and forecasting: Integrating vader and lstm models”, *International Journal of Financial Engineering*, vol. 12, no. 3, hlmn. 2 050 012, 2025.
- [41] C. Jiang dan M. Lu, “Fusion of sentiment and market signals for bitcoin forecasting: A sentistack network based on a stacking lstm architecture”, *Big Data and Cognitive Computing*, vol. 9, no. 6, hlmn. 161, 2025.

LAMPIRAN

